

Tugas Praktikum Pertemuan 1-PEMULUSAN

Adinda Shabrina Putri Salsabila

Library/Packages

```
library("forecast")  
  
library("graphics")  
library("TTR")  
  
library("TSA")
```

Data

Data yang digunakan adalah data time series harga cabai rawit di Provinsi DKI Jakarta dari tanggal 14 Maret 2024 hingga 31 Juli 2024. Data diambil dari website resmi Badan Pangan Nasional.

Impor Data

```
DataMPDW <- read.csv("https://raw.githubusercontent.com/adindashabrina/dataMPDW/main/Data%20MPDW.csv", header = TRUE, sep=",")  
DataMPDW$waktu <- as.Date(DataMPDW$waktu, format = "%Y-%m-%d")  
head(DataMPDW)  
  
##           waktu harga  
## 1 2024-03-14 81090  
## 2 2024-03-15 80000  
## 3 2024-03-16 90670  
## 4 2024-03-17 85730  
## 5 2024-03-18 84340  
## 6 2024-03-19 75040
```

Eksplorasi Data

Melihat data

Melihat menggunakan fungsi View(), struktur data menggunakan fungsi str(), dan dimensi data menggunakan fungsi dim(). Dapat dilihat bahwa data terdiri atas dua variabel yaitu waktu dan harga dengan total 140 baris data.

```
View(DataMPDW)  
str(DataMPDW)  
  
## 'data.frame':   140 obs. of  2 variables:  
## $ waktu: Date, format: "2024-03-14" "2024-03-15" ...  
## $ harga: int  81090 80000 90670 85730 84340 75040 71220 68390 67810 62700  
## ...
```

```
dim(DataMPDW)
## [1] 140 2
```

Mengubah data

Mengubah data agar terbaca sebagai data deret waktu dengan fungsi `ts()` .

```
DataMPDW.ts <- ts(DataMPDW$waktu)
DataMPDW.ts <- ts(DataMPDW$harga)
```


Menampilkan ringkasan data

Ringkasan data yang diperoleh adalah nilai minimum, quartil 1, median, quartil 3, dan nilai maksimum sebagai berikut

```
summary(DataMPDW.ts)
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 38540    44705   49780   53811   60573   90670
```


Membuat plot data deret waktu

```
ts.plot(DataMPDW.ts, xlab="Waktu (hari)", ylab="Harga (rupiah)",
         main = "Harga Cabai Rawit Tahun 2024")
points(DataMPDW.ts)
```



```
ggplot(DataMPDW, aes(x = waktu, y = harga)) +
  geom_line() +
```

```
geom_point() +
theme_minimal() +
labs(title = "Harga Cabai Rawit Tahun 2024",
      x = "Waktu",
      y = "Harga") +
theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Single Moving Average & Double Moving Average

Pembagian Data

Pembagian data latih dan data uji dilakukan dengan perbandingan 87% data latih dan 13% data uji. Karna data yang saya gunakan berjumlah 140, maka 87% data latih adalah amatan ke 1 sampai 123 dan 13% data uji adalah amatan ke 124 sampai 140. Adapun pembagian persentase untuk masing-masing uji ini didasarkan pada garis amatan yang sekiranya baik berdasarkan grafik di atas.

```
#membagi data latih dan data uji
training_ma <- DataMPDW[1:123,]
testing_ma <- DataMPDW[124:140,]
train_ma.ts <- ts(training_ma$harga)
test_ma.ts <- ts(testing_ma$harga)
```

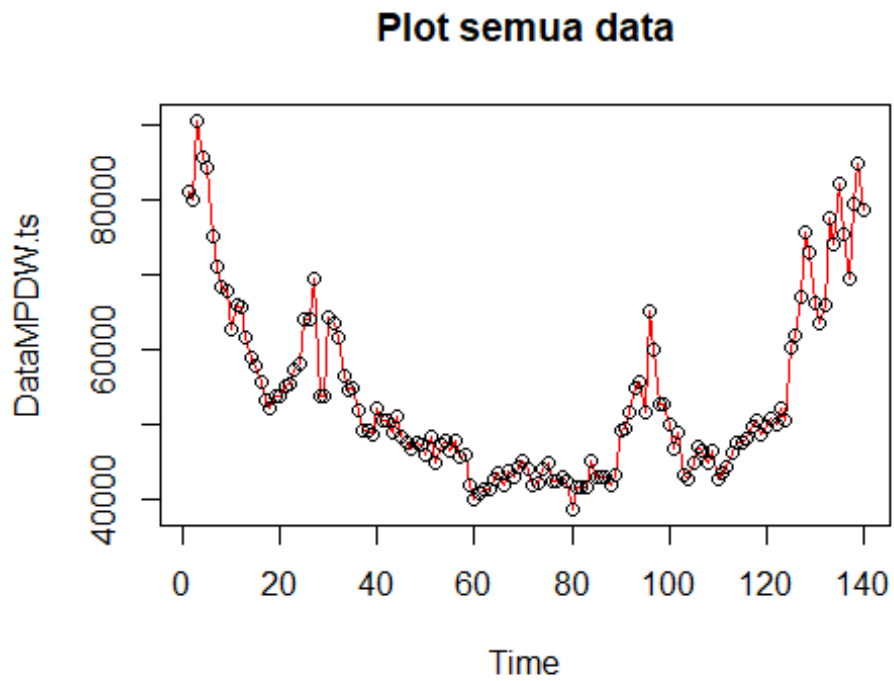
Eksplorasi Data

Eksplorasi data dilakukan pada keseluruhan data, data latih serta data uji menggunakan plot data deret waktu.

```
#eksplorasi keseluruhan data
```

```
plot(DataMPDW.ts, col="red",main="Plot semua data")
```

```
points(DataMPDW.ts)
```




```
#eksplorasi data Latih
```

```
plot(train_ma.ts, col="blue",main="Plot data latih")
```


```
points(train_ma.ts)
```

Plot data latih




```
#eksplorasi data uji  
plot(test_ma.ts, col="blue",main="Plot data uji")  
points(test_ma.ts)
```

Plot data uji



Eksplorasi data juga dapat dilakukan menggunakan package ggplot2 dengan terlebih dahulu memanggil library *package* ggplot2.

```
library(ggplot2)
ggplot() +
  geom_line(data = training_ma, aes(x = waktu, y = harga, col = "Data Latih"))
) +
  geom_line(data = testing_ma, aes(x = waktu, y = harga, col = "Data Uji")) +
  labs(x = "Waktu", y = "Harga", color = "Legend") +
  scale_colour_manual(name="Keterangan:", breaks = c("Data Latih", "Data Uji"),
    values = c("blue", "red")) +
  theme_bw() + theme(legend.position = "bottom",
    plot.caption = element_text(hjust=0.5, size=12))
```



Single Moving Average (SMA)

Ide dasar dari Single Moving Average (SMA) adalah data suatu periode dipengaruhi oleh data periode sebelumnya. Metode pemulusan ini cocok digunakan untuk pola data stasioner atau konstan. Prinsip dasar metode pemulusan ini adalah data pemulusan pada periode ke- t merupakan rata-rata dari m buah data pada periode ke- t hingga periode ke- $(t-m+1)$. Data pemulusan pada periode ke- t selanjutnya digunakan sebagai nilai peramalan pada periode ke- $t+1$.

Pemulusan menggunakan metode SMA dilakukan dengan fungsi `SMA()`. Dalam hal ini akan dilakukan pemulusan dengan parameter $m=4$.

```

data.sma <- SMA(train_ma.ts, n=4)
data.sma

## Time Series:
## Start = 1
## End = 123
## Frequency = 1
## [1]      NA      NA      NA 84372.50 85185.00 83945.00 79082.50 74747
.50
## [9] 70615.00 67530.00 66177.50 65525.00 63957.50 62982.50 61010.00 58452
.50
## [17] 56365.00 54685.00 53610.00 53127.50 53590.00 54390.00 55287.50 56400
.00
## [25] 58665.00 60880.00 63972.50 62907.75 60335.50 60348.00 58798.00 60767
.75
## [33] 61422.50 59040.00 56905.00 54467.50 52642.50 51272.50 49715.00 49760
.00
## [41] 50097.50 50442.50 50475.00 50197.50 49647.50 48875.00 48362.50 47482
.50
## [49] 47207.50 46830.00 47247.50 46555.00 46555.00 47005.00 46480.00 47240
.00
## [57] 46867.50 46372.50 45242.50 43240.00 41965.00 40820.00 40685.00 41382
.50
## [65] 42105.00 42237.50 42857.50 42930.00 43115.00 43950.00 43987.50 43712
.50
## [73] 43165.00 42855.00 43055.00 43225.00 43290.00 43065.00 42457.50 41490
.00
## [81] 41290.00 40930.00 40752.50 42352.50 42687.50 43045.00 43410.00 42602
.50
## [89] 42702.50 44232.50 45842.50 48327.50 51202.50 52832.50 53387.50 56725
.00
## [97] 58042.50 57302.50 57567.50 53797.50 50457.50 49510.00 47157.50 45320
.00
## [105] 44850.00 44375.00 45165.00 45687.50 46102.50 45032.50 44285.00 44142
.50
## [113] 44090.00 45290.00 46290.00 47252.50 48077.50 48810.00 49122.50 49547
.50
## [121] 49822.50 49727.50 50560.00

```

Data pemulusan pada periode ke-t selanjutnya digunakan sebagai nilai peramalan pada periode ke t+1 sehingga hasil peramalan 1 periode kedepan adalah sebagai berikut.

```

data.ramal<-c(NA,data.sma)
data.ramal #forecast 1 periode ke depan

## [1]      NA      NA      NA      NA 84372.50 85185.00 83945.00 79082
.50
## [9] 74747.50 70615.00 67530.00 66177.50 65525.00 63957.50 62982.50 61010
.00
## [17] 58452.50 56365.00 54685.00 53610.00 53127.50 53590.00 54390.00 55287
.50

```

```
## [25] 56400.00 58665.00 60880.00 63972.50 62907.75 60335.50 60348.00 58798
.00
## [33] 60767.75 61422.50 59040.00 56905.00 54467.50 52642.50 51272.50 49715
.00
## [41] 49760.00 50097.50 50442.50 50475.00 50197.50 49647.50 48875.00 48362
.50
## [49] 47482.50 47207.50 46830.00 47247.50 46555.00 46555.00 47005.00 46480
.00
## [57] 47240.00 46867.50 46372.50 45242.50 43240.00 41965.00 40820.00 40685
.00
## [65] 41382.50 42105.00 42237.50 42857.50 42930.00 43115.00 43950.00 43987
.50
## [73] 43712.50 43165.00 42855.00 43055.00 43225.00 43290.00 43065.00 42457
.50
## [81] 41490.00 41290.00 40930.00 40752.50 42352.50 42687.50 43045.00 43410
.00
## [89] 42602.50 42702.50 44232.50 45842.50 48327.50 51202.50 52832.50 53387
.50
## [97] 56725.00 58042.50 57302.50 57567.50 53797.50 50457.50 49510.00 47157
.50
## [105] 45320.00 44850.00 44375.00 45165.00 45687.50 46102.50 45032.50 44285
.00
## [113] 44142.50 44090.00 45290.00 46290.00 47252.50 48077.50 48810.00 49122
.50
## [121] 49547.50 49822.50 49727.50 50560.00
```

Selanjutnya akan dilakukan peramalan sejumlah data uji yaitu 16 hari. Pada metode SMA, hasil peramalan 16 hari ke depan akan bernilai sama dengan hasil peramalan 1 hari kedepan. Dalam hal ini akan dilakukan penggabungan data aktual train, data hasil pemulusan dan data hasil ramalan 16 hari kedepan.

```
data.gab<-cbind(aktual=c(train_ma.ts,rep(NA,17)),pemulusan=c(data.sma,rep(NA,
17)),ramalan=c(data.ramal,rep(data.ramal[length(data.ramal)],16)))
data.gab #forecast 17 hari ke depan
```

```
##      aktual pemulusan ramalan
## [1,] 81090      NA      NA
## [2,] 80000      NA      NA
## [3,] 90670      NA      NA
## [4,] 85730 84372.50      NA
## [5,] 84340 85185.00 84372.50
## [6,] 75040 83945.00 85185.00
## [7,] 71220 79082.50 83945.00
## [8,] 68390 74747.50 79082.50
## [9,] 67810 70615.00 74747.50
## [10,] 62700 67530.00 70615.00
## [11,] 65810 66177.50 67530.00
## [12,] 65780 65525.00 66177.50
## [13,] 61540 63957.50 65525.00
## [14,] 58800 62982.50 63957.50
```


##	[15,]	57920	61010.00	62982.50
##	[16,]	55550	58452.50	61010.00
##	[17,]	53190	56365.00	58452.50
##	[18,]	52080	54685.00	56365.00
##	[19,]	53620	53610.00	54685.00
##	[20,]	53620	53127.50	53610.00
##	[21,]	55040	53590.00	53127.50
##	[22,]	55280	54390.00	53590.00
##	[23,]	57210	55287.50	54390.00
##	[24,]	58070	56400.00	55287.50
##	[25,]	64100	58665.00	56400.00
##	[26,]	64140	60880.00	58665.00
##	[27,]	69580	63972.50	60880.00
##	[28,]	53811	62907.75	63972.50
##	[29,]	53811	60335.50	62907.75
##	[30,]	64190	60348.00	60335.50
##	[31,]	63380	58798.00	60348.00
##	[32,]	61690	60767.75	58798.00
##	[33,]	56430	61422.50	60767.75
##	[34,]	54660	59040.00	61422.50
##	[35,]	54840	56905.00	59040.00
##	[36,]	51940	54467.50	56905.00
##	[37,]	49130	52642.50	54467.50
##	[38,]	49180	51272.50	52642.50
##	[39,]	48610	49715.00	51272.50
##	[40,]	52120	49760.00	49715.00
##	[41,]	50480	50097.50	49760.00
##	[42,]	50560	50442.50	50097.50
##	[43,]	48740	50475.00	50442.50
##	[44,]	51010	50197.50	50475.00
##	[45,]	48280	49647.50	50197.50
##	[46,]	47470	48875.00	49647.50
##	[47,]	46690	48362.50	48875.00
##	[48,]	47490	47482.50	48362.50
##	[49,]	47180	47207.50	47482.50
##	[50,]	45960	46830.00	47207.50
##	[51,]	48360	47247.50	46830.00
##	[52,]	44720	46555.00	47247.50
##	[53,]	47180	46555.00	46555.00
##	[54,]	47760	47005.00	46555.00
##	[55,]	46260	46480.00	47005.00
##	[56,]	47760	47240.00	46480.00
##	[57,]	45690	46867.50	47240.00
##	[58,]	45780	46372.50	46867.50
##	[59,]	41740	45242.50	46372.50
##	[60,]	39750	43240.00	45242.50
##	[61,]	40590	41965.00	43240.00
##	[62,]	41200	40820.00	41965.00
##	[63,]	41200	40685.00	40820.00
##	[64,]	42540	41382.50	40685.00

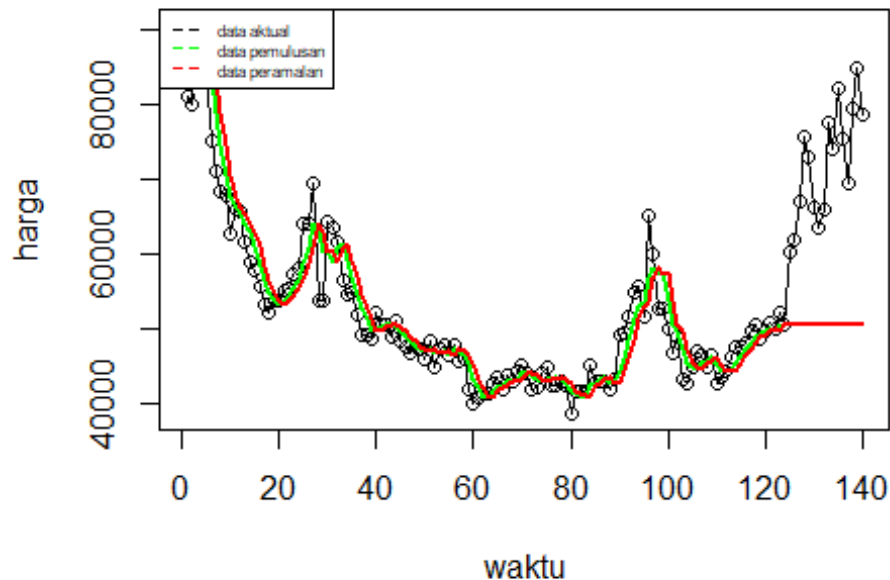
##	[65,]	43480	42105.00	41382.50
##	[66,]	41730	42237.50	42105.00
##	[67,]	43680	42857.50	42237.50
##	[68,]	42830	42930.00	42857.50
##	[69,]	44220	43115.00	42930.00
##	[70,]	45070	43950.00	43115.00
##	[71,]	43830	43987.50	43950.00
##	[72,]	41730	43712.50	43987.50
##	[73,]	42030	43165.00	43712.50
##	[74,]	43830	42855.00	43165.00
##	[75,]	44630	43055.00	42855.00
##	[76,]	42410	43225.00	43055.00
##	[77,]	42290	43290.00	43225.00
##	[78,]	42930	43065.00	43290.00
##	[79,]	42200	42457.50	43065.00
##	[80,]	38540	41490.00	42457.50
##	[81,]	41490	41290.00	41490.00
##	[82,]	41490	40930.00	41290.00
##	[83,]	41490	40752.50	40930.00
##	[84,]	44940	42352.50	40752.50
##	[85,]	42830	42687.50	42352.50
##	[86,]	42920	43045.00	42687.50
##	[87,]	42950	43410.00	43045.00
##	[88,]	41710	42602.50	43410.00
##	[89,]	43230	42702.50	42602.50
##	[90,]	49040	44232.50	42702.50
##	[91,]	49390	45842.50	44232.50
##	[92,]	51650	48327.50	45842.50
##	[93,]	54730	51202.50	48327.50
##	[94,]	55560	52832.50	51202.50
##	[95,]	51610	53387.50	52832.50
##	[96,]	65000	56725.00	53387.50
##	[97,]	60000	58042.50	56725.00
##	[98,]	52600	57302.50	58042.50
##	[99,]	52670	57567.50	57302.50
##	[100,]	49920	53797.50	57567.50
##	[101,]	46640	50457.50	53797.50
##	[102,]	48810	49510.00	50457.50
##	[103,]	43260	47157.50	49510.00
##	[104,]	42570	45320.00	47157.50
##	[105,]	44760	44850.00	45320.00
##	[106,]	46910	44375.00	44850.00
##	[107,]	46420	45165.00	44375.00
##	[108,]	44660	45687.50	45165.00
##	[109,]	46420	46102.50	45687.50
##	[110,]	42630	45032.50	46102.50
##	[111,]	43430	44285.00	45032.50
##	[112,]	44090	44142.50	44285.00
##	[113,]	46210	44090.00	44142.50
##	[114,]	47430	45290.00	44090.00

```
## [115,] 47430 46290.00 45290.00
## [116,] 47940 47252.50 46290.00
## [117,] 49510 48077.50 47252.50
## [118,] 50360 48810.00 48077.50
## [119,] 48680 49122.50 48810.00
## [120,] 49640 49547.50 49122.50
## [121,] 50610 49822.50 49547.50
## [122,] 49980 49727.50 49822.50
## [123,] 52010 50560.00 49727.50
## [124,]      NA      NA 50560.00
## [125,]      NA      NA 50560.00
## [126,]      NA      NA 50560.00
## [127,]      NA      NA 50560.00
## [128,]      NA      NA 50560.00
## [129,]      NA      NA 50560.00
## [130,]      NA      NA 50560.00
## [131,]      NA      NA 50560.00
## [132,]      NA      NA 50560.00
## [133,]      NA      NA 50560.00
## [134,]      NA      NA 50560.00
## [135,]      NA      NA 50560.00
## [136,]      NA      NA 50560.00
## [137,]      NA      NA 50560.00
## [138,]      NA      NA 50560.00
## [139,]      NA      NA 50560.00
## [140,]      NA      NA 50560.00
```

Adapun plot data deret waktu dari hasil peramalan yang dilakukan adalah sebagai berikut.

```
ts.plot(DataMPDW.ts, xlab="waktu", ylab="harga", main= "SMA N=4 Data Harga Ca
bai Rawit")
points(DataMPDW.ts)
lines(data.gab[,2],col="green",lwd=2)
lines(data.gab[,3],col="red",lwd=2)
legend("topleft",c("data aktual","data pemulusan","data peramalan"), lty=8, c
ol=c("black","green","red"), cex=0.5)
```

SMA N=4 Data Harga Cabai Rawit



Selanjutnya perhitungan akurasi dilakukan dengan ukuran akurasi *Sum Squares Error* (SSE), *Mean Square Error* (MSE) dan *Mean Absolute Percentage Error* (MAPE). Perhitungan akurasi dilakukan baik pada data latih maupun pada data uji.

#Menghitung nilai keakuratan data latih

```
error_train.sma = train_ma.ts-data.ramal[1:length(train_ma.ts)]
SSE_train.sma = sum(error_train.sma[5:length(train_ma.ts)]^2)
MSE_train.sma = mean(error_train.sma[5:length(train_ma.ts)]^2)
MAPE_train.sma = mean(abs((error_train.sma[5:length(train_ma.ts)]/train_ma.ts
[5:length(train_ma.ts)]))*100))
```

```
akurasi_train.sma <- matrix(c(SSE_train.sma, MSE_train.sma, MAPE_train.sma))
row.names(akurasi_train.sma)<- c("SSE", "MSE", "MAPE")
colnames(akurasi_train.sma) <- c("Akurasi m = 4")
akurasi_train.sma
```

```
##      Akurasi m = 4
## SSE   1.960304e+09
## MSE   1.647314e+07
## MAPE   5.599684e+00
```

Dalam hal ini nilai MAPE data latih pada metode pemulusan SMA kurang dari 10%, nilai ini dapat dikategorikan sebagai nilai akurasi yang sangat baik. Selanjutnya dilakukan perhitungan nilai MAPE data uji pada metode pemulusan SMA.

#Menghitung nilai keakuratan data uji

```
error_test.sma = test_ma.ts-data.gab[124:140,3]
```

```

SSE_test.sma = sum(error_test.sma^2)
MSE_test.sma = mean(error_test.sma^2)
MAPE_test.sma = mean(abs((error_test.sma/test_ma.ts*100)))

akurasi_test.sma <- matrix(c(SSE_test.sma, MSE_test.sma, MAPE_test.sma))
row.names(akurasi_test.sma)<- c("SSE", "MSE", "MAPE")
colnames(akurasi_test.sma) <- c("Akurasi m = 4")
akurasi_test.sma

##      Akurasi m = 4
## SSE      8.349331e+09
## MSE      4.911371e+08
## MAPE      2.755337e+01

```

Perhitungan akurasi menggunakan data uji menghasilkan nilai MAPE yang lebih dari 10% sehingga nilai akurasi ini dapat dikategorikan sebagai cukup baik.

Double Moving Average (DMA)

Metode pemulusan Double Moving Average (DMA) pada dasarnya mirip dengan SMA. Namun demikian, metode ini lebih cocok digunakan untuk pola data trend. Proses pemulusan dengan rata rata dalam metode ini dilakukan sebanyak 2 kali.

```

dma <- SMA(data.sma, n = 4)
At <- 2*data.sma - dma
Bt <- 2/(4-1)*(data.sma - dma)
data.dma<- At+Bt
data.ramal2<- c(NA, data.dma)

t = 1:17
f = c()

for (i in t) {
  f[i] = At[length(At)] + Bt[length(Bt)]*(i)
}

data.gab2 <- cbind(aktual = c(train_ma.ts,rep(NA,17)), pemulusan1 = c(data.sma,rep(NA,17)),pemulusan2 = c(data.dma, rep(NA,17)),At = c(At, rep(NA,17)), Bt = c(Bt,rep(NA,17)),ramalan = c(data.ramal2, f[-1]))
data.gab2

##      aktual pemulusan1 pemulusan2      At      Bt ramalan
## [1,]  81090          NA          NA      NA      NA      NA
## [2,]  80000          NA          NA      NA      NA      NA
## [3,]  90670          NA          NA      NA      NA      NA
## [4,]  85730    84372.50          NA      NA      NA      NA
## [5,]  84340    85185.00          NA      NA      NA      NA
## [6,]  75040    83945.00          NA      NA      NA      NA
## [7,]  71220    79082.50    72309.58  75018.75 -2709.16667      NA
## [8,]  68390    74747.50    64760.00  68755.00 -3995.00000  72309.58

```

##	[9,]	67810	70615.00	59810.83	64132.50	-4321.66667	64760.00
##	[10,]	62700	67530.00	58423.75	62066.25	-3642.50000	59810.83
##	[11,]	65810	66177.50	60194.17	62587.50	-2393.33333	58423.75
##	[12,]	65780	65525.00	62296.88	63588.12	-1291.25000	60194.17
##	[13,]	61540	63957.50	60890.83	62117.50	-1226.66667	62296.88
##	[14,]	58800	62982.50	60185.62	61304.38	-1118.75000	60890.83
##	[15,]	57920	61010.00	57078.75	58651.25	-1572.50000	60185.62
##	[16,]	55550	58452.50	53205.62	55304.38	-2098.75000	57078.75
##	[17,]	53190	56365.00	50802.50	53027.50	-2225.00000	53205.62
##	[18,]	52080	54685.00	49779.79	51741.88	-1962.08333	50802.50
##	[19,]	53620	53610.00	49996.46	51441.88	-1445.41667	49779.79
##	[20,]	53620	53127.50	50928.54	51808.12	-879.58333	49996.46
##	[21,]	55040	53590.00	53318.12	53426.88	-108.75000	50928.54
##	[22,]	55280	54390.00	55574.38	55100.62	473.75000	53318.12
##	[23,]	57210	55287.50	57268.75	56476.25	792.50000	55574.38
##	[24,]	58070	56400.00	58871.88	57883.12	988.75000	57268.75
##	[25,]	64100	58665.00	62797.29	61144.38	1652.91667	58871.88
##	[26,]	64140	60880.00	65999.79	63951.88	2047.91667	62797.29
##	[27,]	69580	63972.50	70627.71	67965.62	2662.08333	65999.79
##	[28,]	53811	62907.75	65076.81	64209.19	867.62500	70627.71
##	[29,]	53811	60335.50	57521.44	58647.06	-1125.62500	65076.81
##	[30,]	64190	60348.00	57776.44	58805.06	-1028.62500	57521.44
##	[31,]	63380	58798.00	55799.15	56998.69	-1199.54167	57776.44
##	[32,]	61690	60767.75	61943.48	61473.19	470.29167	55799.15
##	[33,]	56430	61422.50	63236.56	62510.94	725.62500	61943.48
##	[34,]	54660	59040.00	57428.23	58072.94	-644.70833	63236.56
##	[35,]	54840	56905.00	52523.65	54276.19	-1752.54167	57428.23
##	[36,]	51940	54467.50	48648.75	50976.25	-2327.50000	52523.65
##	[37,]	49130	52642.50	47440.42	49521.25	-2080.83333	48648.75
##	[38,]	49180	51272.50	47023.54	48723.12	-1699.58333	47440.42
##	[39,]	48610	49715.00	45866.04	47405.62	-1539.58333	47023.54
##	[40,]	52120	49760.00	47947.50	48672.50	-725.00000	45866.04
##	[41,]	50480	50097.50	49907.92	49983.75	-75.83333	47947.50
##	[42,]	50560	50442.50	51173.75	50881.25	292.50000	49907.92
##	[43,]	48740	50475.00	50943.75	50756.25	187.50000	51173.75
##	[44,]	51010	50197.50	50021.46	50091.88	-70.41667	50943.75
##	[45,]	48280	49647.50	48742.29	49104.38	-362.08333	50021.46
##	[46,]	47470	48875.00	47335.42	47951.25	-615.83333	48742.29
##	[47,]	46690	48362.50	46848.96	47454.38	-605.41667	47335.42
##	[48,]	47490	47482.50	45633.54	46373.12	-739.58333	46848.96
##	[49,]	47180	47207.50	45916.88	46433.12	-516.25000	45633.54
##	[50,]	45960	46830.00	45762.29	46189.38	-427.08333	45916.88
##	[51,]	48360	47247.50	47340.21	47303.12	37.08333	45762.29
##	[52,]	44720	46555.00	45880.00	46150.00	-270.00000	47340.21
##	[53,]	47180	46555.00	46151.88	46313.12	-161.25000	45880.00
##	[54,]	47760	47005.00	47278.96	47169.38	109.58333	46151.88
##	[55,]	46260	46480.00	46198.75	46311.25	-112.50000	47278.96
##	[56,]	47760	47240.00	47940.00	47660.00	280.00000	46198.75
##	[57,]	45690	46867.50	46816.46	46836.88	-20.41667	47940.00
##	[58,]	45780	46372.50	45760.00	46005.00	-245.00000	46816.46

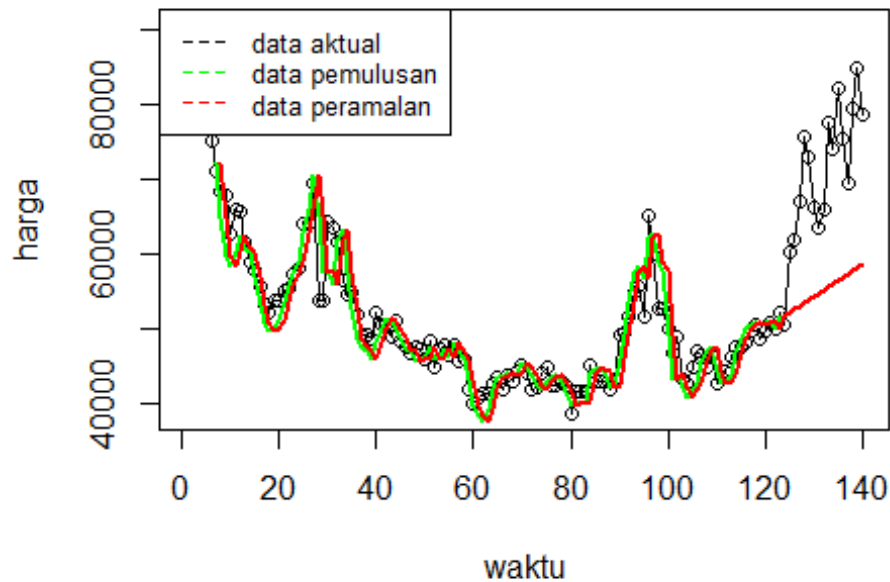
##	[59,]	41740	45242.50	43262.29	44054.38	-792.08333	45760.00
##	[60,]	39750	43240.00	39588.96	41049.38	-1460.41667	43262.29
##	[61,]	40590	41965.00	38231.67	39725.00	-1493.33333	39588.96
##	[62,]	41200	40820.00	37491.88	38823.12	-1331.25000	38231.67
##	[63,]	41200	40685.00	39030.83	39692.50	-661.66667	37491.88
##	[64,]	42540	41382.50	41664.79	41551.88	112.91667	39030.83
##	[65,]	43480	42105.00	43533.12	42961.88	571.25000	41664.79
##	[66,]	41730	42237.50	43295.83	42872.50	423.33333	43533.12
##	[67,]	43680	42857.50	44043.96	43569.38	474.58333	43295.83
##	[68,]	42830	42930.00	43592.50	43327.50	265.00000	44043.96
##	[69,]	44220	43115.00	43665.00	43445.00	220.00000	43592.50
##	[70,]	45070	43950.00	45178.12	44686.88	491.25000	43665.00
##	[71,]	43830	43987.50	44807.29	44479.38	327.91667	45178.12
##	[72,]	41730	43712.50	43747.92	43733.75	14.16667	44807.29
##	[73,]	42030	43165.00	42267.08	42626.25	-359.16667	43747.92
##	[74,]	43830	42855.00	41896.67	42280.00	-383.33333	42267.08
##	[75,]	44630	43055.00	42818.54	42913.12	-94.58333	41896.67
##	[76,]	42410	43225.00	43475.00	43375.00	100.00000	42818.54
##	[77,]	42290	43290.00	43596.25	43473.75	122.50000	43475.00
##	[78,]	42930	43065.00	42908.75	42971.25	-62.50000	43596.25
##	[79,]	42200	42457.50	41537.71	41905.62	-367.91667	42908.75
##	[80,]	38540	41490.00	39680.62	40404.38	-723.75000	41537.71
##	[81,]	41490	41290.00	39980.62	40504.38	-523.75000	39680.62
##	[82,]	41490	40930.00	39910.21	40318.12	-407.91667	39980.62
##	[83,]	41490	40752.50	40147.29	40389.38	-242.08333	39910.21
##	[84,]	44940	42352.50	44054.58	43373.75	680.83333	40147.29
##	[85,]	42830	42687.50	44365.62	43694.38	671.25000	44054.58
##	[86,]	42920	43045.00	44437.71	43880.62	557.08333	44365.62
##	[87,]	42950	43410.00	44303.75	43946.25	357.50000	44437.71
##	[88,]	41710	42602.50	42046.25	42268.75	-222.50000	44303.75
##	[89,]	43230	42702.50	42306.67	42465.00	-158.33333	42046.25
##	[90,]	49040	44232.50	45891.88	45228.12	663.75000	42306.67
##	[91,]	49390	45842.50	49171.67	47840.00	1331.66667	45891.88
##	[92,]	51650	48327.50	53412.92	51378.75	2034.16667	49171.67
##	[93,]	54730	51202.50	57537.92	55003.75	2534.16667	53412.92
##	[94,]	55560	52832.50	58301.25	56113.75	2187.50000	57537.92
##	[95,]	51610	53387.50	56637.50	55337.50	1300.00000	58301.25
##	[96,]	65000	56725.00	62038.54	59913.12	2125.41667	56637.50
##	[97,]	60000	58042.50	62701.88	60838.12	1863.75000	62038.54
##	[98,]	52600	57302.50	58866.04	58240.62	625.41667	62701.88
##	[99,]	52670	57567.50	57831.04	57725.62	105.41667	58866.04
##	[100,]	49920	53797.50	48997.50	50917.50	-1920.00000	57831.04
##	[101,]	46640	50457.50	43251.25	46133.75	-2882.50000	48997.50
##	[102,]	48810	49510.00	43971.46	46186.88	-2215.41667	43251.25
##	[103,]	43260	47157.50	42035.62	44084.38	-2048.75000	43971.46
##	[104,]	42570	45320.00	40667.92	42528.75	-1860.83333	42035.62
##	[105,]	44760	44850.00	41751.04	42990.62	-1239.58333	40667.92
##	[106,]	46910	44375.00	42623.96	43324.38	-700.41667	41751.04
##	[107,]	46420	45165.00	45560.83	45402.50	158.33333	42623.96
##	[108,]	44660	45687.50	46801.04	46355.62	445.41667	45560.83

## [109,]	46420	46102.50	47385.83	46872.50	513.33333	46801.04
## [110,]	42630	45032.50	44258.54	44568.12	-309.58333	47385.83
## [111,]	43430	44285.00	42631.88	43293.12	-661.25000	44258.54
## [112,]	44090	44142.50	42895.62	43394.38	-498.75000	42631.88
## [113,]	46210	44090.00	43594.17	43792.50	-198.33333	42895.62
## [114,]	47430	45290.00	46686.88	46128.12	558.75000	43594.17
## [115,]	47430	46290.00	48518.12	47626.88	891.25000	46686.88
## [116,]	47940	47252.50	49788.96	48774.38	1014.58333	48518.12
## [117,]	49510	48077.50	50327.50	49427.50	900.00000	49788.96
## [118,]	50360	48810.00	50814.17	50012.50	801.66667	50327.50
## [119,]	48680	49122.50	50467.29	49929.38	537.91667	50814.17
## [120,]	49640	49547.50	50644.38	50205.62	438.75000	50467.29
## [121,]	50610	49822.50	50650.62	50319.38	331.25000	50644.38
## [122,]	49980	49727.50	50015.00	49900.00	115.00000	50650.62
## [123,]	52010	50560.00	51636.04	51205.62	430.41667	50015.00
## [124,]	NA	NA	NA	NA	NA	51636.04
## [125,]	NA	NA	NA	NA	NA	52066.46
## [126,]	NA	NA	NA	NA	NA	52496.88
## [127,]	NA	NA	NA	NA	NA	52927.29
## [128,]	NA	NA	NA	NA	NA	53357.71
## [129,]	NA	NA	NA	NA	NA	53788.12
## [130,]	NA	NA	NA	NA	NA	54218.54
## [131,]	NA	NA	NA	NA	NA	54648.96
## [132,]	NA	NA	NA	NA	NA	55079.38
## [133,]	NA	NA	NA	NA	NA	55509.79
## [134,]	NA	NA	NA	NA	NA	55940.21
## [135,]	NA	NA	NA	NA	NA	56370.62
## [136,]	NA	NA	NA	NA	NA	56801.04
## [137,]	NA	NA	NA	NA	NA	57231.46
## [138,]	NA	NA	NA	NA	NA	57661.88
## [139,]	NA	NA	NA	NA	NA	58092.29
## [140,]	NA	NA	NA	NA	NA	58522.71

Hasil pemulusan menggunakan metode DMA divisualisasikan sebagai berikut

```
ts.plot(DataMPDW.ts, xlab="waktu", ylab="harga", main= "DMA N=4 Data Harga Ca
bai Rawit")
points(DataMPDW.ts)
lines(data.gab2[,3],col="green",lwd=2)
lines(data.gab2[,6],col="red",lwd=2)
legend("topleft",c("data aktual","data pemulusan","data peramalan"), lty=8, c
ol=c("black","green","red"), cex=0.8)
```


DMA N=4 Data Harga Cabai Rawit



Selanjutnya perhitungan akurasi dilakukan baik pada data latih maupun data uji. Perhitungan akurasi dilakukan dengan ukuran akurasi SSE, MSE dan MAPE.

#Menghitung nilai keakuratan data Latih

```
error_train.dma = train_ma.ts-data.ramal2[1:length(train_ma.ts)]
SSE_train.dma = sum(error_train.dma[8:length(train_ma.ts)]^2)
MSE_train.dma = mean(error_train.dma[8:length(train_ma.ts)]^2)
MAPE_train.dma = mean(abs((error_train.dma[8:length(train_ma.ts)]/train_ma.ts
[8:length(train_ma.ts)]))*100))
```

```
akurasi_train.dma <- matrix(c(SSE_train.dma, MSE_train.dma, MAPE_train.dma))
row.names(akurasi_train.dma)<- c("SSE", "MSE", "MAPE")
colnames(akurasi_train.dma) <- c("Akurasi m = 4")
akurasi_train.dma
```

```
##      Akurasi m = 4
## SSE   1.655536e+09
## MSE   1.427187e+07
## MAPE   5.393489e+00
```

Perhitungan akurasi pada data latih menggunakan nilai MAPE menghasilkan nilai MAPE yang kurang dari 10% sehingga dikategorikan sangat baik. Selanjutnya, perhitungan nilai akurasi dilakukan pada data uji.

#Menghitung nilai keakuratan data uji

```
error_test.dma = test_ma.ts-data.gab2[124:140,6]
SSE_test.dma = sum(error_test.dma^2)
```

```

MSE_test.dma = mean(error_test.dma^2)
MAPE_test.dma = mean(abs((error_test.dma/test_ma.ts*100)))

akurasi_test.dma <- matrix(c(SSE_test.dma, MSE_test.dma, MAPE_test.dma))
row.names(akurasi_test.dma)<- c("SSE", "MSE", "MAPE")
colnames(akurasi_test.dma) <- c("Akurasi m = 4")
akurasi_test.dma

##      Akurasi m = 4
## SSE    5.148463e+09
## MSE    3.028508e+08
## MAPE    2.164339e+01

```

Perhitungan akurasi menggunakan data uji menghasilkan nilai MAPE yang lebih dari 10% sehingga nilai akurasi ini dapat dikategorikan cukup baik.

KESIMPULAN : Pada data latih maupun data uji, metode DMA lebih baik dibandingkan dengan metode SMA karena nilai MAPE data latih dan data uji pada metode DMA lebih kecil dibandingkan nilai MAPE pada metode SMA.

Single Exponential Smoothing & Double Exponential Smoothing

Metode *Exponential Smoothing* adalah metode pemulusan dengan melakukan pembobotan menurun secara eksponensial. Nilai yang lebih baru diberi bobot yang lebih besar dari nilai terdahulu. Terdapat satu atau lebih parameter pemulusan yang ditentukan secara eksplisit, dan hasil pemilihan parameter tersebut akan menentukan bobot yang akan diberikan pada nilai pengamatan. Ada dua macam model, yaitu model tunggal dan ganda.

Pembagian Data

Pembagian data latih dan data uji dilakukan dengan perbandingan 87% data latih dan 13% data uji. Karena data yang saya gunakan berjumlah 140, maka 87% data latih adalah amatan ke 1 sampai 123 dan 13% data uji adalah amatan ke 124 sampai 140.

```

#membagi training dan testing
training<-DataMPDW[1:123,]
testing<-DataMPDW[124:140,]
train.ts <- ts(training$harga)
test.ts  <- ts(testing$harga)

```

Eksplorasi


Eksplorasi dilakukan dengan membuat plot data deret waktu untuk keseluruhan data, data latih, dan data uji.

```

#eksplorasi data
plot(DataMPDW.ts, col="black",main="Plot semua data")
points(DataMPDW.ts)


```

Plot semua data

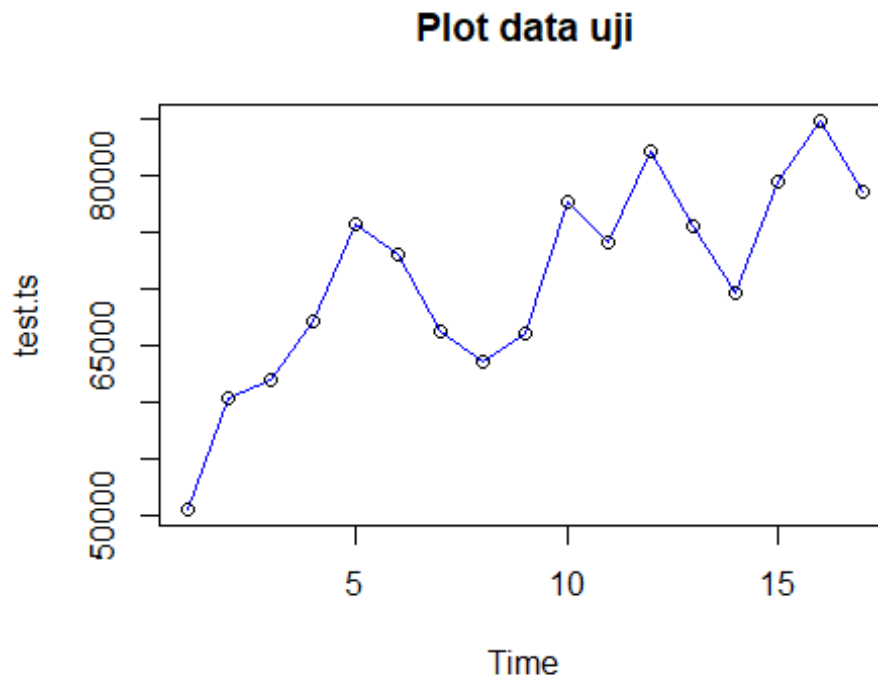


```
plot(train.ts, col="red",main="Plot data latihan")  
points(train.ts)
```

Plot data latihan




```
plot(test.ts, col="blue",main="Plot data uji")
points(test.ts)
```



Eksplorasi data juga dapat dilakukan menggunakan package ggplot2 .

```
#Eksplorasi dengan GGLOT
library(ggplot2)
ggplot() +
  geom_line(data = training, aes(x = waktu, y = harga, col = "Data Latih")) +
  geom_line(data = testing, aes(x = waktu, y = harga, col = "Data Uji")) +
  labs(x = "Waktu", y = "Harga Cabai Rawit", color = "Legend") +
  scale_colour_manual(name="Keterangan:", breaks = c("Data Latih", "Data Uji"
),
                      values = c("blue", "red")) +
  theme_bw() + theme(legend.position = "bottom",
                     plot.caption = element_text(hjust=0.5, size=12))
```



SES

Single Exponential Smoothing merupakan metode pemulusan yang tepat digunakan untuk data dengan pola stasioner atau konstan.

Nilai pemulusan pada periode ke- t didapat dari persamaan:

$$\tilde{y}_T = \lambda y_t + (1 - \lambda)\tilde{y}_{T-1}$$

Nilai parameter λ adalah nilai antara 0 dan 1.


Nilai pemulusan periode ke- t bertindak sebagai nilai ramalan pada periode ke- $(T + \tau)$.

$$\tilde{y}_{T+\tau}(T) = \tilde{y}_T$$

Pemulusan dengan metode SES dapat dilakukan dengan dua fungsi dari *packages* berbeda, yaitu (1) fungsi `ses()` dari *packages forecast* dan (2) fungsi `HoltWinters` dari *packages stats*.

```
#Cara 1 (fungsi ses)
ses.1 <- ses(train.ts, h = 17, alpha = 0.2)
plot(ses.1)
```

Forecasts from Simple exponential smoothing




```
ses.1
```

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## 124		49585.34	43317.39	55853.30	39999.33	59171.36
## 125		49585.34	43193.26	55977.43	39809.49	59361.20
## 126		49585.34	43071.49	56099.20	39623.27	59547.42
## 127		49585.34	42951.96	56218.73	39440.46	59730.23
## 128		49585.34	42834.55	56336.14	39260.89	59909.80
## 129		49585.34	42719.14	56451.55	39084.39	60086.30
## 130		49585.34	42605.64	56565.05	38910.81	60259.88
## 131		49585.34	42493.96	56676.73	38740.01	60430.68
## 132		49585.34	42384.01	56786.68	38571.85	60598.84
## 133		49585.34	42275.71	56894.98	38406.23	60764.46
## 134		49585.34	42169.00	57001.69	38243.02	60927.67
## 135		49585.34	42063.79	57106.89	38082.13	61088.56
## 136		49585.34	41960.04	57210.65	37923.45	61247.24
## 137		49585.34	41857.69	57313.00	37766.91	61403.78
## 138		49585.34	41756.67	57414.02	37612.42	61558.27
## 139		49585.34	41656.93	57513.75	37459.89	61710.80
## 140		49585.34	41558.44	57612.25	37309.26	61861.43

```
ses.2<- ses(train.ts, h = 17, alpha = 0.7)  
plot(ses.2)
```

Forecasts from Simple exponential smoothing

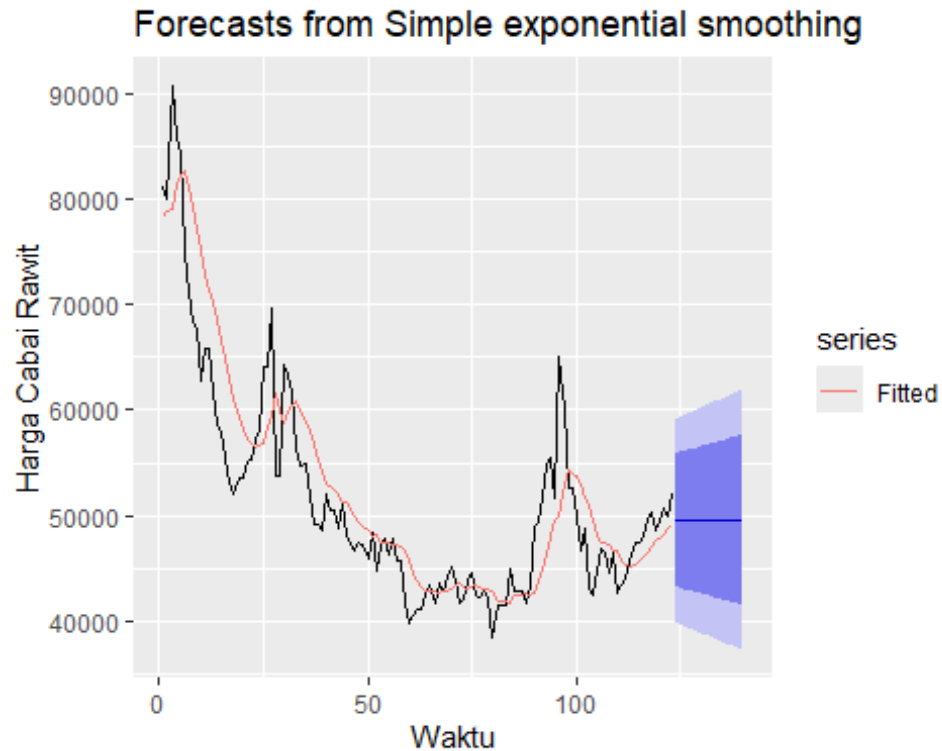


ses.2

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
##	124	51426.81	47067.19	55786.43	44759.34	58094.27
##	125	51426.81	46105.21	56748.40	43288.13	59565.49
##	126	51426.81	45292.28	57561.34	42044.85	60808.76
##	127	51426.81	44575.13	58278.49	40948.06	61905.55
##	128	51426.81	43926.23	58927.38	39955.67	62897.95
##	129	51426.81	43329.17	59524.45	39042.54	63811.08
##	130	51426.81	42773.21	60080.41	38192.27	64661.35
##	131	51426.81	42250.87	60602.75	37393.42	65460.20
##	132	51426.81	41756.70	61096.92	36637.66	66215.96
##	133	51426.81	41286.59	61567.03	35918.68	66934.94
##	134	51426.81	40837.33	62016.29	35231.59	67622.03
##	135	51426.81	40406.36	62447.25	34572.49	68281.13
##	136	51426.81	39991.63	62861.99	33938.21	68915.41
##	137	51426.81	39591.42	63262.20	33326.14	69527.47
##	138	51426.81	39204.31	63649.31	32734.11	70119.51
##	139	51426.81	38829.09	64024.53	32160.26	70693.36
##	140	51426.81	38464.72	64388.89	31603.01	71250.61

Untuk mendapatkan gambar hasil pemulusan pada data latih dengan fungsi `ses()`, perlu digunakan fungsi `autoplot()` dan `autolayer()` dari *library packages* `ggplot2`.

```
autoplot(ses.1) +
  autolayer(fitted(ses.1), series="Fitted") +
  ylab("Harga Cabai Rawit") + xlab("Waktu")
```




Pada fungsi `ses()`, terdapat beberapa argumen yang umum digunakan, yaitu nilai y , γ , β , α , dan h .

Nilai y adalah nilai data deret waktu, γ adalah parameter pemulusan untuk komponen musiman, β adalah parameter pemulusan untuk tren, dan α adalah parameter pemulusan untuk stasioner, serta h adalah banyaknya periode yang akan diramalkan.

Kasus di atas merupakan contoh inisialisasi nilai parameter λ dengan nilai α 0,2 dan 0,7 dan banyak periode data yang akan diramalkan adalah sebanyak 17 hari. Selanjutnya akan digunakan fungsi `HoltWinters()` dengan nilai inisialisasi parameter dan panjang periode peramalan yang sama dengan fungsi `ses()`.

```
#Cara 2 (fungsi Holtwinter)
ses1<- HoltWinters(train.ts, gamma = FALSE, beta = FALSE, alpha = 0.2)
plot(ses1)
```


Holt-Winters filtering



```
#ramalan
```


```
ramalan1<- forecast(ses1, h=17)
```

```
ramalan1
```

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
##	124	49585.34	43516.99	55653.70	40304.60	58866.09
##	125	49585.34	43396.81	55773.87	40120.80	59049.88
##	126	49585.34	43278.93	55891.76	39940.51	59230.18
##	127	49585.34	43163.20	56007.49	39763.53	59407.16
##	128	49585.34	43049.53	56121.16	39589.68	59581.01
##	129	49585.34	42937.80	56232.89	39418.80	59751.89
##	130	49585.34	42827.91	56342.78	39250.74	59919.95
##	131	49585.34	42719.79	56450.90	39085.38	60085.31
##	132	49585.34	42613.34	56557.35	38922.58	60248.11
##	133	49585.34	42508.49	56662.20	38762.23	60408.46
##	134	49585.34	42405.17	56765.52	38604.22	60566.47
##	135	49585.34	42303.32	56867.37	38448.45	60722.24
##	136	49585.34	42202.87	56967.81	38294.83	60875.86
##	137	49585.34	42103.78	57066.91	38143.27	61027.42
##	138	49585.34	42005.97	57164.72	37993.70	61176.99
##	139	49585.34	41909.42	57261.27	37846.03	61324.66
##	140	49585.34	41814.06	57356.63	37700.19	61470.50

```
ses2<- HoltWinters(train.ts, gamma = FALSE, beta = FALSE, alpha = 0.7)  
plot(ses2)
```

Holt-Winters filtering



```
#ramalan
ramalan2<- forecast(ses2, h=17)
ramalan2
```


##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
##	124	51426.81	47089.80	55763.82	44793.93	58059.69
##	125	51426.81	46132.81	56720.80	43330.34	59523.27
##	126	51426.81	45324.10	57529.52	42093.52	60760.10
##	127	51426.81	44610.66	58242.95	41002.41	61851.20
##	128	51426.81	43965.14	58888.48	40015.17	62838.45
##	129	51426.81	43371.17	59482.45	39106.78	63746.84
##	130	51426.81	42818.09	60035.53	38260.91	64592.71
##	131	51426.81	42298.46	60555.16	37466.21	65387.41
##	132	51426.81	41806.86	61046.76	36714.36	66139.25
##	133	51426.81	41339.18	61514.43	35999.12	66854.50
##	134	51426.81	40892.25	61961.37	35315.59	67538.03
##	135	51426.81	40463.52	62390.09	34659.91	68193.71
##	136	51426.81	40050.94	62802.68	34028.92	68824.70
##	137	51426.81	39652.81	63200.81	33420.03	69433.59
##	138	51426.81	39267.70	63585.91	32831.06	70022.55
##	139	51426.81	38894.43	63959.19	32260.19	70593.43
##	140	51426.81	38531.95	64321.66	31705.83	71147.79

Fungsi `Holtwinters` memiliki argumen yang sama dengan fungsi `ses()`. Argumen-argumen kedua fungsi dapat dilihat lebih lanjut dengan `?ses()` atau `?Holtwinters`.

Nilai parameter α dari kedua fungsi dapat dioptimalkan menyesuaikan dari *error*-nya paling minimumnya. Caranya adalah dengan membuat parameter $\alpha = \text{NULL}$.

```
#SES
ses.opt <- ses(train.ts, h = 17, alpha = NULL)
plot(ses.opt)
```

Forecasts from Simple exponential smoothing



```
ses.opt
```

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
##	124	51716.41	47405.70	56027.12	45123.74	58309.07
##	125	51716.41	46058.31	57374.51	43063.09	60369.72
##	126	51716.41	44975.04	58457.77	41406.38	62026.43
##	127	51716.41	44043.22	59389.60	39981.28	63451.54
##	128	51716.41	43212.90	60219.92	38711.41	64721.40
##	129	51716.41	42456.73	60976.08	37554.96	65877.86
##	130	51716.41	41757.82	61674.99	36486.06	66946.75
##	131	51716.41	41104.84	62327.97	35487.42	67945.39
##	132	51716.41	40489.78	62943.03	34546.76	68886.05
##	133	51716.41	39906.71	63526.11	33655.03	69777.79
##	134	51716.41	39351.10	64081.72	32805.30	70627.52
##	135	51716.41	38819.40	64613.41	31992.14	71440.68
##	136	51716.41	38308.77	65124.04	31211.20	72221.61
##	137	51716.41	37816.89	65615.92	30458.93	72973.88
##	138	51716.41	37341.83	66090.98	29732.39	73700.42
##	139	51716.41	36881.98	66550.83	29029.11	74403.71
##	140	51716.41	36435.96	66996.85	28346.98	75085.84

```
#Lamda Optimum Holt Winter
```

```
sesopt<- HoltWinters(train.ts, gamma = FALSE, beta = FALSE,alpha = NULL)  
sesopt
```

```
## Holt-Winters exponential smoothing without trend and without seasonal component.  
##
```

```
## Call:  
## HoltWinters(x = train.ts, alpha = NULL, beta = FALSE, gamma = FALSE)  
##
```

```
## Smoothing parameters:
```

```
## alpha: 0.8502217
```

```
## beta : FALSE
```

```
## gamma: FALSE
```

```
##
```


```
## Coefficients:
```

```
##      [,1]
```

```
## a 51716.46
```

```
plot(sesopt)
```

Holt-Winters filtering



```
#ramalan
```

```
ramalanopt<- forecast(sesopt, h=17)
```

```
ramalanopt
```

```
##      Point Forecast    Lo 80    Hi 80    Lo 95    Hi 95
```

```
## 124          51716.46 47421.17 56011.74 45147.38 58285.53
```

```
## 125      51716.46 46078.53 57354.38 43093.99 60338.92
## 126      51716.46 44999.10 58433.81 41443.14 61989.77
## 127      51716.46 44070.57 59362.34 40023.08 63409.83
## 128      51716.46 43243.18 60189.73 38757.71 64675.20
## 129      51716.46 42489.70 60943.21 37605.35 65827.56
## 130      51716.46 41793.26 61639.65 36540.24 66892.67
## 131      51716.46 41142.60 62290.31 35545.14 67887.77
## 132      51716.46 40529.72 62903.19 34607.81 68825.10
## 133      51716.46 39948.71 63484.20 33719.24 69713.67
## 134      51716.46 39395.07 64037.84 32872.52 70560.39
## 135      51716.46 38865.26 64567.65 32062.25 71370.66
## 136      51716.46 38356.44 65076.47 31284.08 72148.83
## 137      51716.46 37866.30 65566.61 30534.48 72898.43
## 138      51716.46 37392.93 66039.98 29810.51 73622.40
## 139      51716.46 36934.71 66498.20 29109.72 74323.19
## 140      51716.46 36490.27 66942.64 28430.01 75002.90
```

Setelah dilakukan peramalan, akan dilakukan perhitungan keakuratan hasil peramalan. Perhitungan akurasi ini dilakukan baik pada data latih dan data uji.

Akurasi Data Latih

Perhitungan akurasi data dapat dilakukan dengan cara langsung maupun manual. Secara langsung, nilai akurasi dapat diambil dari objek yang tersimpan pada hasil SES, yaitu *sum of squared errors* (SSE). Nilai akurasi lain dapat dihitung pula dari nilai SSE tersebut.

```
#Keakuratan Metode
#Pada data training
SSE1<-ses1$SSE
MSE1<-ses1$SSE/length(train.ts)
RMSE1<-sqrt(MSE1)

akurasi1 <- matrix(c(SSE1,MSE1,RMSE1))
row.names(akurasi1)<- c("SSE", "MSE", "RMSE")
colnames(akurasi1) <- c("Akurasi lamda=0.2")
akurasi1

##      Akurasi lamda=0.2
## SSE      2.916422e+09
## MSE      2.371075e+07
## RMSE      4.869368e+03

SSE2<-ses2$SSE
MSE2<-ses2$SSE/length(train.ts)
RMSE2<-sqrt(MSE2)

akurasi2 <- matrix(c(SSE2,MSE2,RMSE2))
row.names(akurasi2)<- c("SSE", "MSE", "RMSE")
colnames(akurasi2) <- c("Akurasi lamda=0.7")
akurasi2
```

```

##      Akurasi lamda=0.7
## SSE      1.400498e+09
## MSE      1.138616e+07
## RMSE      3.374338e+03

#Cara Manual
fitted1<-ramalan1$fitted
sisaan1<-ramalan1$residuals
head(sisaan1)

## Time Series:
## Start = 1
## End = 6
## Frequency = 1
## [1]      NA -1090.000  9798.000  2898.400   928.720 -8557.024

resid1<-training$harga-ramalan1$fitted
head(resid1)

## Time Series:
## Start = 1
## End = 6
## Frequency = 1
## [1]      NA -1090.000  9798.000  2898.400   928.720 -8557.024

#Cara Manual
SSE.1=sum(sisaan1[2:length(train.ts)]^2)
SSE.1

## [1] 2916421757

MSE.1 = SSE.1/length(train.ts)
MSE.1

## [1] 23710746

MAPE.1 = sum(abs(sisaan1[2:length(train.ts)]/train.ts[2:length(train.ts)]))*
          100)/length(train.ts)
MAPE.1

## [1] 6.740305

akurasi.1 <- matrix(c(SSE.1,MSE.1,MAPE.1))
row.names(akurasi.1)<- c("SSE", "MSE", "MAPE")
colnames(akurasi.1) <- c("Akurasi lamda=0.2")
akurasi.1

##      Akurasi lamda=0.2
## SSE      2.916422e+09
## MSE      2.371075e+07
## MAPE      6.740305e+00

```

```

fitted2<-ramalan2$fitted
sisaan2<-ramalan2$residuals
head(sisaan2)

## Time Series:
## Start = 1
## End = 6
## Frequency = 1
## [1]          NA -1090.000 10343.000 -1837.100 -1941.130 -9882.339

resid2<-training$harga-ramalan2$fitted
head(resid2)

## Time Series:
## Start = 1
## End = 6
## Frequency = 1
## [1]          NA -1090.000 10343.000 -1837.100 -1941.130 -9882.339

SSE.2=sum(sisaan2[2:length(train.ts)]^2)
SSE.2

## [1] 1400497659

MSE.2 = SSE.2/length(train.ts)
MSE.2

## [1] 11386160

MAPE.2 = sum(abs(sisaan2[2:length(train.ts)]/train.ts[2:length(train.ts)]))*
          100)/length(train.ts)
MAPE.2

## [1] 4.379033

akurasi.2 <- matrix(c(SSE.2,MSE.2,MAPE.2))
row.names(akurasi.2)<- c("SSE", "MSE", "MAPE")
colnames(akurasi.2) <- c("Akurasi lamda=0.7")
akurasi.2

##      Akurasi lamda=0.7
## SSE      1.400498e+09
## MSE      1.138616e+07
## MAPE      4.379033e+00

```

Berdasarkan nilai SSE, MSE, RMSE, dan MAPE di antara kedua parameter, nilai parameter $\lambda = 0,7$ menghasilkan akurasi yang lebih baik dibanding $\lambda = 0,2$. Hal ini dilihat dari nilai masing-masing ukuran akurasi yang lebih kecil. Berdasarkan nilai MAPE-nya, hasil ini dapat dikategorikan sebagai peramalan sangat baik.

Akurasi Data Uji

Akurasi data uji dapat dihitung dengan cara yang hampir sama dengan perhitungan akurasi data latih.

```
selisih1<-ramalan1$mean-testing$harga
SSEtesting1<-sum(selisih1^2)
MSEtesting1<-SSEtesting1/length(testing)

selisih2<-ramalan2$mean-testing$harga
SSEtesting2<-sum(selisih2^2)
MSEtesting2<-SSEtesting2/length(testing)

selisihopt<-ramalanopt$mean-testing$harga
SSEtestingopt<-sum(selisihopt^2)
MSEtestingopt<-SSEtestingopt/length(testing)

akurasitesting1 <- matrix(c(SSEtesting1,SSEtesting2,SSEtestingopt))
row.names(akurasitesting1)<- c("SSE1", "SSE2", "SSEopt")
akurasitesting1

##           [,1]
## SSE1    9040857528
## SSE2    7761457384
## SSEopt   7570712345

akurasitesting2 <- matrix(c(MSEtesting1,MSEtesting2,MSEtestingopt))
row.names(akurasitesting2)<- c("MSE1", "MSE2", "MSEopt")
akurasitesting2

##           [,1]
## MSE1    4520428764
## MSE2    3880728692
## MSEopt   3785356172
```

Selain dengan cara di atas, perhitungan nilai akurasi dapat menggunakan fungsi `accuracy()` dari *package* `forecast`. Penggunaannya yaitu dengan menuliskan `accuracy(hasil ramalan, kondisi aktual)`. Contohnya adalah sebagai berikut.

```
#cara lain
accuracy(ramalanopt,testing$harga)

##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -283.1812 3349.856 2272.388 -0.6297878 4.248449 1.023984
## Test set     19224.1332 21102.986 19368.422 25.8796183 26.165395 8.727801
##           ACF1
## Training set 0.0001672648
## Test set     NA
```

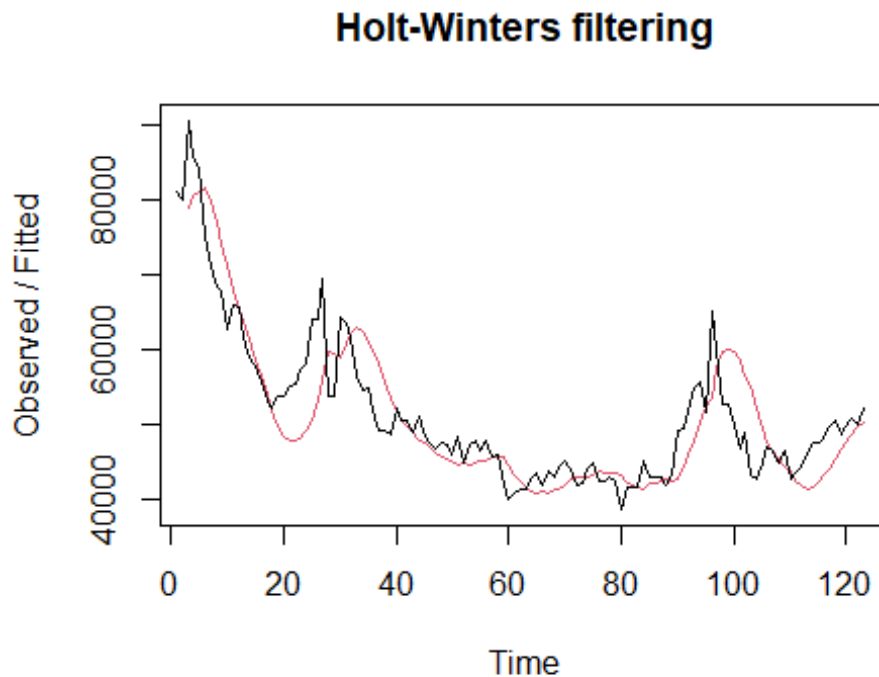
Perhitungan akurasi menggunakan data uji menghasilkan nilai MAPE yang lebih dari 10% sehingga nilai akurasi ini dapat dikategorikan sebagai cukup baik.

DES

Metode pemulusan *Double Exponential Smoothing* (DES) digunakan untuk data yang memiliki pola tren. Metode DES adalah metode semacam SES, hanya saja dilakukan dua kali, yaitu pertama untuk tahapan 'level' dan kedua untuk tahapan 'tren'. Pemulusan menggunakan metode ini akan menghasilkan peramalan tidak konstan untuk periode berikutnya.

Pemulusan dengan metode DES kali ini akan menggunakan fungsi `HoltWinters()`. Jika sebelumnya nilai argumen `beta` dibuat `FALSE`, kali ini argumen tersebut akan diinisialisasi bersamaan dengan nilai `alpha`.

```
#Lamda=0.2 dan gamma=0.2
des.1<- HoltWinters(train.ts, gamma = FALSE, beta = 0.2, alpha = 0.2)
plot(des.1)
```




```
#ramalan
ramalandes1<- forecast(des.1, h=17)
ramalandes1
```

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
##	124	51343.15	44807.22	57879.07	41347.31	61338.98
##	125	52054.71	45333.19	58776.24	41775.03	62334.40
##	126	52766.28	45800.08	59732.48	42112.39	63420.17
##	127	53477.84	46204.44	60751.24	42354.14	64601.55
##	128	54189.41	46544.89	61833.93	42498.13	65880.69
##	129	54900.97	46821.77	62980.18	42544.90	67257.05

```
## 130      55612.54 47036.77 64188.31 42497.03 68728.05
## 131      56324.11 47192.50 65455.71 42358.53 70289.68
## 132      57035.67 47292.10 66779.24 42134.17 71937.17
## 133      57747.24 47338.89 68155.58 41829.05 73665.42
## 134      58458.80 47336.20 69581.40 41448.25 75469.35
## 135      59170.37 47287.20 71053.53 40996.63 77344.10
## 136      59881.93 47194.83 72569.03 40478.68 79285.18
## 137      60593.50 47061.77 74125.23 39898.50 81288.49
## 138      61305.06 46890.42 75719.70 39259.77 83350.35
## 139      62016.63 46682.95 77350.30 38565.80 85467.46
## 140      62728.19 46441.28 79015.11 37819.51 87636.88
```

#Lamda=0.6 dan gamma=0.3

```
des.2<- HoltWinters(train.ts, gamma = FALSE, beta = 0.3, alpha = 0.6)
plot(des.2)
```



#ramalan


```
ramalandes2<- forecast(des.2, h=17)
ramalandes2
```

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## 124		51986.50	47318.10	56654.89	44846.8026	59126.19
## 125		52517.43	46596.85	58438.02	43462.6802	61572.19
## 126		53048.37	45622.83	60473.91	41691.9922	64404.75
## 127		53579.31	44443.56	62715.06	39607.3809	67551.23
## 128		54110.24	43090.46	65130.03	37256.9372	70963.55
## 129		54641.18	41584.69	67697.67	34673.0012	74609.36

```
## 130      55172.12 39941.13  70403.11 31878.3274  78465.91
## 131      55703.05 38170.76  73235.35 28889.7268  82516.38
## 132      56233.99 36282.08  76185.90 25720.1744  86747.81
## 133      56764.93 34281.87  79247.99 22380.0579  91149.80
## 134      57295.87 32175.74  82415.99 18877.9450  95713.79
## 135      57826.80 29968.41  85685.19 15221.0740 100432.53
## 136      58357.74 27663.98  89051.50 11415.6798 105299.80
## 137      58888.68 25265.99  92511.36  7467.2178 110310.14
## 138      59419.61 22777.62  96061.61  3380.5232 115458.70
## 139      59950.55 20201.70  99699.40  -840.0724 120741.17
## 140      60481.49 17540.78 103422.19 -5190.6542 126153.63
```

Selanjutnya jika ingin membandingkan plot data latih dan data uji adalah sebagai berikut.

```
#Visually evaluate the prediction
plot(DataMPDW.ts)
lines(des.1$fitted[,1], lty=2, col="blue")
lines(ramalandes1$mean, col="red")
```




Untuk mendapatkan nilai parameter optimum dari DES, argumen alpha dan beta dapat dibuat NULL seperti berikut.

```
#Lamda dan gamma optimum
des.opt<- HoltWinters(train.ts, gamma = FALSE)
des.opt

## Holt-Winters exponential smoothing with trend and without seasonal compone
nt.
```

```
##
## Call:
## HoltWinters(x = train.ts, gamma = FALSE)
##
## Smoothing parameters:
## alpha: 0.8274969
## beta : 0.02795107
## gamma: FALSE
##
## Coefficients:
##      [,1]
## a 51672.97243
## b   44.27825
plot(des.opt)
```



```
#ramalan
ramalandesopt<- forecast(des.opt, h=17)
ramalandesopt
```

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
##	124	51717.25	47400.17	56034.33	45114.84	58319.66
##	125	51761.53	46093.86	57429.20	43093.58	60429.48
##	126	51805.81	44997.65	58613.96	41393.63	62217.98
##	127	51850.09	44017.92	59682.25	39871.82	63828.35
##	128	51894.36	43112.69	60676.04	38463.95	65324.78
##	129	51938.64	42258.97	61618.31	37134.86	66742.42

```
## 130      51982.92 41442.65 62523.19 35862.97 68102.87
## 131      52027.20 40654.35 63400.04 34633.93 69420.46
## 132      52071.48 39887.52 64255.44 33437.72 70705.24
## 133      52115.75 39137.35 65094.16 32266.99 71964.52
## 134      52160.03 38400.23 65919.83 31116.24 73203.83
## 135      52204.31 37673.38 66735.24 29981.17 74427.45
## 136      52248.59 36954.59 67542.59 28858.43 75638.75
## 137      52292.87 36242.08 68343.65 27745.31 76840.42
## 138      52337.15 35534.42 69139.87 26639.60 78034.69
## 139      52381.42 34830.42 69932.43 25539.47 79223.38
## 140      52425.70 34129.07 70722.34 24443.42 80407.99
```

Selanjutnya akan dilakukan perhitungan akurasi pada data latih maupun data uji dengan ukuran akurasi SSE, MSE dan MAPE.

Akurasi Data Latih

#Akurasi Data Training

```
ssedes.train1<-des.1$SSE
msedes.train1<-ssedes.train1/length(train.ts)
sisaandes1<-ramalandes1$residuals
head(sisaandes1)

## Time Series:
## Start = 1
## End = 6
## Frequency = 1
## [1]      NA      NA 11760.000  5087.600  3096.176 -6530.810

mapedes.train1 <- sum(abs(sisaandes1[3:length(train.ts)]/train.ts[3:length(tr
ain.ts)]))
                    *100)/length(train.ts)

akurasides.1 <- matrix(c(ssedes.train1,msedes.train1,mapedes.train1))
row.names(akurasides.1)<- c("SSE", "MSE", "MAPE")
colnames(akurasides.1) <- c("Akurasi lamda=0.2 dan gamma=0.2")
akurasides.1

##      Akurasi lamda=0.2 dan gamma=0.2
## SSE      3.137975e+09
## MSE      2.551199e+07
## MAPE      7.015581e+00

ssedes.train2<-des.2$SSE
msedes.train2<-ssedes.train2/length(train.ts)
sisaandes2<-ramalandes2$residuals
head(sisaandes2)

## Time Series:
## Start = 1
## End = 6
```

```
## Frequency = 1
## [1]          NA          NA  11760.000  -1262.800  -2694.616  -10692.312

mapedes.train2 <- sum(abs(sisaandes2[3:length(train.ts)]/train.ts[3:length(tr
ain.ts)]))
                    *100)/length(train.ts)

akurasides.2 <- matrix(c(ssedes.train2,msedes.train2,mapedes.train2))
row.names(akurasides.2)<- c("SSE", "MSE", "MAPE")
colnames(akurasides.2) <- c("Akurasi lamda=0.6 dan gamma=0.3")
akurasides.2

##      Akurasi lamda=0.6 dan gamma=0.3
## SSE                                1.593041e+09
## MSE                                1.295155e+07
## MAPE                               4.640332e+00
```

Hasil akurasi dari data latih didapatkan skenario 2 dengan lamda=0.6 dan gamma=0.3 memiliki hasil yang lebih baik. Namun untuk kedua skenario dapat dikategorikan peramalan sangat baik berdasarkan nilai MAPE-nya.

Akurasi Data Uji

#Akurasi Data Testing

```
selisihdes1<-ramalandes1$mean-testing$harga
selisihdes1
```

```
## Time Series:
## Start = 124
## End = 140
## Frequency = 1
## [1]    853.1478  -8195.2869  -9073.7216 -13562.1563 -21470.5909 -18199.02
56
## [7] -10587.4603  -7245.8950  -8944.3297 -19972.7643 -15591.1990 -23039.63
37
## [13] -15578.0684  -8946.5030 -18094.9377 -22833.3724 -15901.8071
```

```
SSEtestingdes1<-sum(selisihdes1^2)
MSEtestingdes1<-SSEtestingdes1/length(testing$harga)
MAPEtestingdes1<-sum(abs(selisihdes1/testing$harga)*100)/length(testing$harga
)
```

```
selisihdes2<-ramalandes2$mean-testing$harga
selisihdes2
```

```
## Time Series:
## Start = 124
## End = 140
## Frequency = 1
## [1]   1496.496  -7732.567  -8791.630 -13460.693 -21549.756 -18458.819
## [7] -11027.882  -7866.945  -9746.008 -20955.071 -16754.134 -24383.197
## [13] -17102.260 -10651.323 -19980.387 -24899.450 -18148.513
```

```

SSEtestingdes2<-sum(selisihdes2^2)
MSEtestingdes2<-SSEtestingdes2/length(testing$harga)
MAPEtestingdes2<-sum(abs(selisihdes2/testing$harga)*100)/length(testing$harga)
)

selisihdesopt<-ramalandesopt$mean-testing$harga
selisihdesopt

## Time Series:
## Start = 124
## End = 140
## Frequency = 1
## [1] 1227.251 -8488.471 -10034.193 -15189.915 -23765.636 -21161.358
## [7] -14217.080 -11542.802 -13908.523 -25604.245 -21889.967 -30005.689
## [13] -23211.410 -17247.132 -27062.854 -32468.576 -26204.297

SSEtestingdesopt<-sum(selisihdesopt^2)
MSEtestingdesopt<-SSEtestingdesopt/length(testing$harga)
MAPEtestingdesopt<-sum(abs(selisihdesopt/testing$harga)*100)/length(testing$harga)

akurasitestingdes <-
  matrix(c(SSEtestingdes1,MSEtestingdes1,MAPEtestingdes1,SSEtestingdes2,MSEtestingdes2,
    MAPEtestingdes2,SSEtestingdesopt,MSEtestingdesopt,MAPEtestingdesopt),
    nrow=3,ncol=3)
row.names(akurasitestingdes)<- c("SSE", "MSE", "MAPE")
colnames(akurasitestingdes) <- c("des ske1","des ske2","des opt")
akurasitestingdes

##           des ske1      des ske2      des opt
## SSE  3.968139e+09 4.472984e+09 7.290990e+09
## MSE  2.334199e+08 2.631167e+08 4.288818e+08
## MAPE 1.897809e+01 2.014416e+01 2.568932e+01

```

Perhitungan akurasi menggunakan data uji menghasilkan nilai MAPE yang lebih dari 10% untuk semua skenario sehingga nilai akurasi ini dapat dikategorikan sebagai cukup baik.

Perbandingan SES dan DES

```

MSEfull <-
  matrix(c(MSEtesting1,MSEtesting2,MSEtestingopt,MSEtestingdes1,MSEtestingdes2,
    MSEtestingdesopt),nrow=3,ncol=2)
row.names(MSEfull)<- c("ske 1", "ske 2", "ske opt")
colnames(MSEfull) <- c("ses","des")
MSEfull

##           ses      des
## ske 1  4520428764 233419943

```

```
## ske 2    3880728692 263116710  
## ske opt 3785356172 428881773
```

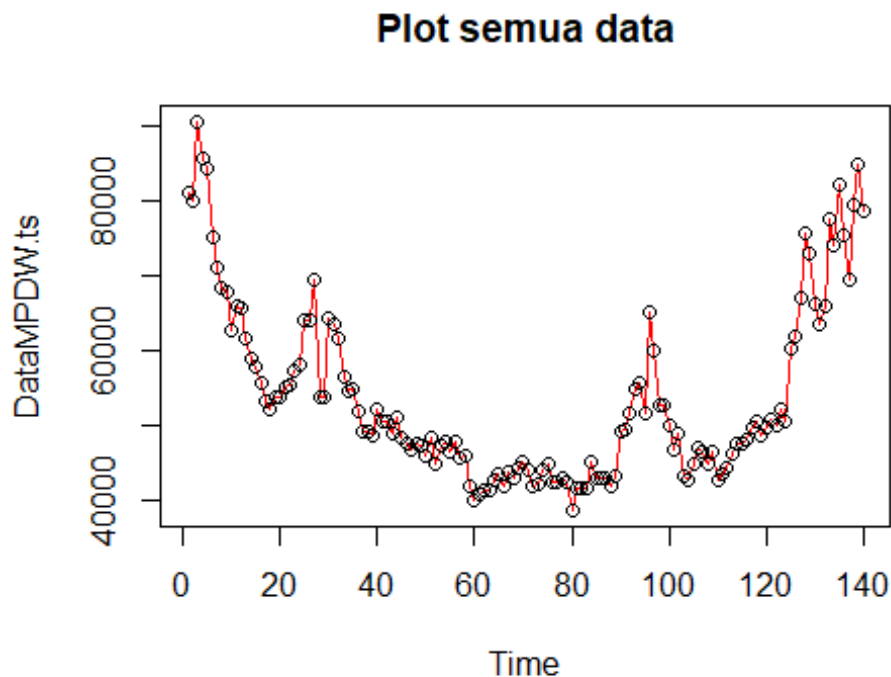
KESIMPULAN : Kedua metode dapat dibandingkan dengan menggunakan ukuran akurasi yang sama. Contoh di atas adalah perbandingan kedua metode dengan ukuran akurasi MSE. Hasilnya didapatkan metode DES lebih baik dibandingkan metode SES dilihat dari MSE yang lebih kecil nilainya.

Pemulusan Data Musiman

```
#membagi data menjadi training dan testing  
training<-DataMPDW[1:123,2]  
testing<-DataMPDW[124:140,2]  
training.ts<-ts(training, frequency = 14)  
testing.ts<-ts(testing, frequency = 14)
```


Kemudian akan dilakukan eskplorasi dengan plot data deret waktu sebagai berikut.

```
#Membuat plot time series  
plot(DataMPDW.ts, col="red",main="Plot semua data")  
points(DataMPDW.ts)
```




```
plot(training.ts, col="blue",main="Plot data latih")  
points(training.ts)
```


Plot data latih



```
plot(testing.ts, col="green",main="Plot data uji")  
points(testing.ts)
```

Plot data uji



Metode Holt-Winter untuk peramalan data musiman menggunakan tiga persamaan pemulusan yang terdiri atas persamaan untuk level (L_t), trend (B_t), dan komponen seasonal / musiman (S_t) dengan parameter pemulusan berupa α , β , dan γ . Metode Holt-Winter musiman terbagi menjadi dua, yaitu metode aditif dan metode multiplikatif.

Pemulusan data musiman dengan metode Winter dilakukan menggunakan fungsi `HoltWinters()` dengan memasukkan argumen tambahan, yaitu `gamma()` dan `seasonal()`. Argumen `seasonal()` diinisialisasi menyesuaikan jenis musiman, aditif atau multiplikatif.

Winter Aditif

Perhitungan dengan model aditif dilakukan jika plot data asli menunjukkan fluktuasi musiman yang relatif stabil (konstan).

Pemulusan

#Pemulusan dengan winter aditif

```
winter1 <- HoltWinters(training.ts,alpha=0.2,beta=0.1,gamma=0.1,seasonal = "additive")
```

```
winter1$fitted
```

```
## Time Series:
```

```
## Start = c(2, 1)
```

```
## End = c(9, 11)
```

```
## Frequency = 14
```

##		xhat	level	trend	season
##	2.000000	70495.26	70344.57	-1146.63242	1297.32398
##	2.071429	65058.86	66682.88	-1398.13759	-225.89031
##	2.142857	59752.70	63382.97	-1588.31469	-2041.96173
##	2.214286	55837.02	60482.12	-1719.56865	-2925.53316
##	2.285714	54950.55	58011.15	-1794.70902	-1265.89031
##	2.357143	52634.55	55950.33	-1821.31999	-1494.46173
##	2.428571	52341.06	54326.10	-1801.61093	-183.42602
##	2.500000	50081.11	53064.28	-1747.63219	-1235.53316
##	2.571429	50597.95	52356.42	-1643.65440	-114.81888
##	2.642857	47510.73	52035.18	-1511.41337	-3013.03316
##	2.714286	53972.71	52635.62	-1300.22800	2637.32398
##	2.785714	57169.42	53360.85	-1097.68228	4906.25255
##	2.857143	55227.41	53657.28	-958.27063	2528.39541
##	2.928571	56029.56	55569.53	-671.21875	1131.25255
##	3.000000	54030.31	54454.60	-715.59002	291.30329
##	3.071429	51988.57	53695.15	-719.97625	-986.59871
##	3.142857	52372.53	55415.46	-475.94767	-2566.97757
##	3.214286	53659.11	57141.00	-255.79827	-3226.09462
##	3.285714	57023.87	58491.38	-95.18045	-1372.33418
##	3.357143	56754.74	58277.43	-107.05779	-1415.62552
##	3.428571	57634.96	57751.42	-148.95268	32.48897
##	3.500000	56019.00	57043.48	-204.85183	-819.62203
##	3.571429	56150.54	56022.82	-286.43189	414.14524
##	3.642857	51737.15	54332.29	-426.84265	-2168.29166
##	3.714286	56363.53	53394.01	-477.98566	3447.50685

##	3.785714	56196.16	51365.32	-633.05633	5463.89915
##	3.857143	52879.05	49917.03	-714.57959	3676.60291
##	3.928571	48913.85	48722.64	-762.56067	953.76748
##	4.000000	47833.43	48289.31	-729.63762	273.75837
##	4.071429	47019.00	47740.99	-711.50624	-10.48438
##	4.142857	45509.61	47827.68	-631.68616	-1686.37998
##	4.214286	44590.17	47750.07	-576.27846	-2583.62333
##	4.285714	45811.23	47749.76	-518.68187	-1419.84355
##	4.357143	45322.52	47406.83	-501.10655	-1583.20508
##	4.428571	46690.36	47339.22	-457.75693	-191.10763
##	4.500000	45385.49	46979.39	-447.96405	-1145.94228
##	4.571429	46062.36	46646.33	-436.47377	-147.49779
##	4.642857	43906.00	46669.39	-390.52096	-2372.86372
##	4.714286	48894.65	46441.66	-374.24097	2827.22418
##	4.785714	50453.77	45724.49	-408.53392	5137.80613
##	4.857143	47799.48	44777.21	-462.40924	3484.67856
##	4.928571	44599.16	44006.90	-493.19876	1085.45969
##	5.000000	44062.17	44145.87	-429.98203	346.28388
##	5.071429	43952.82	44041.45	-397.42548	308.79594
##	5.142857	42183.83	44009.46	-360.88198	-1464.74918
##	5.214286	40836.82	43559.82	-369.75863	-2353.23695
##	5.285714	41231.66	42972.69	-391.49502	-1349.54227
##	5.357143	40638.73	42452.87	-404.32813	-1409.80662
##	5.428571	41615.75	42160.79	-393.10277	-151.93610
##	5.500000	40183.14	41684.54	-401.41784	-1099.98116
##	5.571429	41436.53	41754.49	-354.28063	36.31345
##	5.642857	39187.75	41808.91	-313.41115	-2307.74377
##	5.714286	44431.43	42003.95	-262.56619	2690.05238
##	5.785714	46235.80	41591.09	-277.59483	4922.30485
##	5.857143	43648.15	40632.34	-345.71089	3361.52048
##	5.928571	41405.05	40401.00	-334.27383	1338.32663
##	6.000000	41015.25	40799.71	-260.97483	476.51006
##	6.071429	41351.98	41101.69	-204.67980	454.96996
##	6.142857	39275.24	40972.61	-197.11938	-1500.25580
##	6.214286	38744.24	41326.45	-142.02415	-2440.18253
##	6.285714	40760.39	42201.57	-40.30894	-1400.87471
##	6.357143	41607.37	42935.19	37.08325	-1364.90517
##	6.428571	43000.74	43132.80	53.13595	-185.19636
##	6.500000	42171.27	43043.79	38.92121	-911.43233
##	6.571429	43488.34	43234.45	54.09571	199.79139
##	6.642857	40954.84	43030.88	28.32893	-2104.36395
##	6.714286	45186.21	42576.24	-19.96797	2629.93784
##	6.785714	46372.98	41817.03	-93.89217	4649.84060
##	6.857143	43962.26	40746.54	-191.55174	3407.26870
##	6.928571	41451.06	40060.54	-240.99692	1631.52263
##	7.000000	41047.80	40517.33	-171.21821	701.69017
##	7.071429	41052.19	40702.55	-135.57422	485.21164
##	7.142857	39562.45	40940.54	-98.21798	-1279.87484
##	7.214286	39456.04	41519.83	-30.46690	-2033.32169
##	7.285714	40863.46	41940.16	14.61225	-1091.30595

```
## 7.357143 41189.32 42428.08    61.94300 -1300.69439
## 7.428571 44037.06 44060.15   218.95651 -242.05531
## 7.500000 44824.98 45349.70   326.01541 -850.73432
## 7.571429 47599.96 47040.72   462.51580   96.72425
## 7.642857 47236.81 48929.24   605.11662 -2297.55155
## 7.714286 54304.82 51199.00   771.58047  2334.24105
## 7.785714 56408.50 51431.61   717.68408  4259.20233
## 7.857143 57966.60 53867.60   889.51406  3209.48797
## 7.928571 58004.61 55163.79   930.18206  1910.63748
## 8.000000 56679.41 55013.05   822.08982   844.26611
## 8.071429 56409.80 55033.26   741.90166   634.63661
## 8.142857 54080.44 54477.20   612.10569 -1008.87051
## 8.214286 52211.51 53601.22   463.29694 -1853.00513
## 8.285714 52877.50 53384.21   395.26670 -901.98294
## 8.357143 51386.26 51855.98   202.91672 -672.64034
## 8.428571 50508.42 50295.65    26.59156   186.18028
## 8.500000 48779.45 49172.55   -88.37682 -304.73276
## 8.571429 49251.65 48710.29 -125.76572   667.12755
## 8.642857 46204.10 48018.19 -182.39873 -1631.69618
## 8.714286 49432.35 47526.97 -213.28070  2118.65551
## 8.785714 51384.22 46711.22 -273.52769  4946.52226
## 8.857143 47610.40 44686.85 -448.61206  3372.15994
## 8.928571 44348.21 43402.16 -532.22007  1478.26854
## 9.000000 42804.43 42818.30 -537.38425   523.51347
## 9.071429 42608.21 42962.03 -469.27281   115.45273
## 9.142857 41480.17 43457.11 -372.83698 -1604.10550
## 9.214286 41895.28 44274.24 -253.84042 -2125.12610
## 9.285714 43425.02 45229.35 -132.94594 -1671.38283
## 9.357143 44924.21 46313.40  -11.24631 -1377.94100
## 9.428571 47213.09 47389.31    97.46948  -273.69322
## 9.500000 47452.68 47780.16   126.80777  -454.28837
## 9.571429 48955.58 48344.43   170.55415   440.59549
## 9.642857 47294.29 48845.87   203.64249 -1755.22403
## 9.714286 51721.68 49586.66   257.35671  1877.66755
```

```
xhat1 <- winter1$fitted[,2]
```

```
winter1.opt<- HoltWinters(training.ts, alpha= NULL, beta = NULL, gamma = NULL,
seasonal = "additive")
winter1.opt
```

```
## Holt-Winters exponential smoothing with trend and additive seasonal component.
```

```
##
```

```
## Call:
```

```
## HoltWinters(x = training.ts, alpha = NULL, beta = NULL, gamma = NULL,
seasonal = "additive")
```

```
##
```

```
## Smoothing parameters:
```

```
## alpha: 0.7633572
```

```

## beta : 0.03265924
## gamma: 0.3474856
##
## Coefficients:
##          [,1]
## a    50903.78413
## b      64.12201
## s1    4521.18184
## s2    3573.61693
## s3    1617.40199
## s4     697.60319
## s5     585.40494
## s6   -1206.47027
## s7   -1945.62054
## s8   -1814.80842
## s9   -1146.73723
## s10  -375.14136
## s11  -219.74497
## s12   281.58421
## s13 -1830.60179
## s14  1255.81889

winter1.opt$fitted

## Time Series:
## Start = c(2, 1)
## End = c(9, 11)
## Frequency = 14
##          xhat    level    trend    season
## 2.000000 70495.26 70344.57 -1146.632418 1297.32398
## 2.071429 57912.49 59598.52 -1460.141997 -225.89031
## 2.142857 52773.95 56334.96 -1519.040409 -2041.96173
## 2.214286 50699.31 55133.51 -1508.668107 -2925.53316
## 2.285714 51938.67 54678.80 -1474.246490 -1265.89031
## 2.357143 51561.22 54488.01 -1432.329690 -1494.46173
## 2.428571 53062.84 54627.27 -1381.003009 -183.42602
## 2.500000 52188.30 54755.54 -1331.711040 -1235.53316
## 2.571429 54414.45 55783.90 -1254.632913 -114.81888
## 2.642857 52465.30 56663.27 -1184.938061 -3013.03316
## 2.714286 61348.84 59756.72 -1045.209191 2637.32398
## 2.785714 64741.26 60811.63 -976.620846 4906.25255
## 2.857143 60912.82 59376.03 -991.610772 2528.39541
## 2.928571 65356.30 65000.58 -775.532125 1131.25255
## 3.000000 54611.76 55411.86 -1063.364107 263.26081
## 3.071429 52233.75 53737.23 -1083.327492 -420.15767
## 3.142857 58987.80 61780.80 -785.250142 -2007.75029
## 3.214286 60860.62 64348.37 -675.749564 -2811.99875
## 3.285714 62523.02 64305.73 -655.072528 -1127.63418
## 3.357143 56867.36 58999.50 -806.975697 -1325.16856
## 3.428571 55624.67 56507.52 -862.006667 -20.84404

```

##	3.500000	53183.66	55046.53	-881.569110	-981.30281
##	3.571429	52418.09	53215.61	-912.574371	115.05888
##	3.642857	46246.34	49793.04	-994.548657	-2552.15896
##	3.714286	52980.07	51037.93	-921.410471	2863.55210
##	3.785714	50607.05	46780.59	-1030.359233	4856.81058
##	3.857143	49153.62	46905.16	-992.640257	3241.09762
##	3.928571	46147.33	46925.02	-959.572640	181.88299
##	4.000000	48681.74	49333.89	-849.561928	197.41465
##	4.071429	48243.69	48528.80	-848.109565	563.00467
##	4.142857	47366.65	49792.37	-779.143726	-1646.57946
##	4.214286	46210.27	49710.44	-756.373198	-2743.79872
##	4.285714	47562.06	49915.69	-724.967260	-1628.66344
##	4.357143	46271.64	48525.03	-746.708339	-1506.67976
##	4.428571	47906.66	48708.36	-716.333874	-85.36775
##	4.500000	45619.31	47437.33	-734.450056	-1083.56890
##	4.571429	46081.67	46962.95	-725.956385	-155.32070
##	4.642857	44996.09	47976.17	-669.156088	-2310.92389
##	4.714286	48924.42	47096.26	-676.039200	2504.20135
##	4.785714	49350.30	45088.60	-719.528773	4981.22083
##	4.857143	45746.10	43155.11	-759.175897	3350.16607
##	4.928571	42586.60	42788.22	-746.364061	544.73642
##	5.000000	45575.83	45991.01	-617.387647	202.20505
##	5.071429	45636.71	45460.78	-614.541363	790.47789
##	5.142857	42773.17	44955.61	-610.969159	-1571.47437
##	5.214286	40279.03	43555.97	-636.726802	-2640.21106
##	5.285714	40165.11	42515.40	-649.915849	-1700.37305
##	5.357143	40144.01	42189.83	-639.323135	-1406.49425
##	5.428571	41598.48	42356.60	-612.996581	-145.12119
##	5.500000	39760.93	41439.42	-622.931049	-1055.55383
##	5.571429	42416.29	42937.91	-553.647098	32.02635
##	5.642857	40335.50	43196.25	-527.128029	-2333.62678
##	5.714286	45602.02	43733.63	-492.362185	2360.75767
##	5.785714	46084.25	41774.08	-540.279514	4850.45089
##	5.857143	41520.66	38749.64	-621.410055	3392.42395
##	5.928571	40604.83	40188.80	-554.113639	970.14530
##	6.000000	42812.00	43043.20	-442.793915	211.59308
##	6.071429	43762.35	43377.51	-417.414568	802.26025
##	6.142857	39284.17	41408.68	-468.082430	-1656.43200
##	6.214286	39953.31	43036.65	-399.626973	-2683.71311
##	6.285714	43627.91	45596.32	-302.978511	-1665.43461
##	6.357143	44460.64	46058.30	-277.995718	-1319.66016
##	6.428571	43707.92	44214.93	-329.119568	-177.88851
##	6.500000	41611.93	42803.43	-364.469298	-827.03136
##	6.571429	43233.01	43445.12	-331.608905	119.49542
##	6.642857	39748.64	42324.96	-357.362428	-2218.95699
##	6.714286	42860.19	41044.97	-387.494593	2202.70973
##	6.785714	43772.74	39611.54	-421.654288	4582.85426
##	6.857143	40583.17	37447.34	-478.564401	3614.39083
##	6.928571	38542.37	37661.01	-455.956403	1337.31630
##	7.000000	42087.57	42088.73	-296.459300	295.30296

```
## 7.071429 42716.20 42359.01 -277.950147 635.14010
## 7.142857 40533.12 42236.63 -272.869212 -1430.64220
## 7.214286 41231.16 43808.70 -212.614785 -2364.93301
## 7.285714 42177.91 43961.62 -200.676913 -1583.03271
## 7.357143 42901.33 44564.06 -174.447574 -1488.28432
## 7.428571 48759.72 49075.61 -21.406463 -294.48416
## 7.500000 48810.99 49535.33 -5.693206 -718.64641
## 7.571429 51796.45 51696.82 65.085113 34.55138
## 7.642857 51821.12 54001.25 138.220409 -2318.34331
## 7.714286 59315.04 56993.56 231.433111 2090.03923
## 7.785714 55777.79 51343.30 39.341399 4395.14500
## 7.857143 62380.70 58422.48 269.257268 3688.95984
## 7.928571 58947.71 56874.42 209.904779 1863.39298
## 8.000000 52646.75 52238.75 51.652039 356.35255
## 8.071429 53012.28 52308.15 52.231613 651.89878
## 8.142857 48743.10 49999.87 -24.860901 -1231.90223
## 8.214286 45966.74 48369.59 -77.292664 -2325.55777
## 8.285714 48959.79 50462.72 -6.408199 -1496.51927
## 8.357143 44973.32 46105.33 -148.507820 -983.50174
## 8.428571 43671.15 44122.23 -208.424305 -242.65639
## 8.500000 44078.51 44744.99 -181.278563 -485.19500
## 8.571429 46890.23 46725.14 -110.687741 275.77692
## 8.642857 44122.19 46255.50 -122.410974 -2010.89553
## 8.714286 47891.08 46543.63 -109.003110 1456.45424
## 8.785714 50319.48 45311.67 -145.678083 5153.48716
## 8.857143 42451.98 39296.17 -337.381821 3493.19478
## 8.928571 40733.79 39705.36 -312.999253 1341.42064
## 9.000000 42083.29 41954.36 -229.326610 358.26419
## 9.071429 45146.36 44875.18 -126.445055 397.62097
## 9.142857 45017.62 46491.97 -69.512292 -1404.84034
## 9.214286 46162.84 48263.97 -9.370012 -2091.75626
## 9.285714 47680.93 49611.20 34.935739 -1965.21303
## 9.357143 49941.78 51042.38 80.535745 -1181.12706
## 9.428571 51380.00 51442.16 90.962130 -153.12034
## 9.500000 49243.34 49472.06 23.649300 -252.36202
## 9.571429 50069.14 49798.50 33.538210 237.10964
## 9.642857 48325.25 50244.90 47.022112 -1966.67176
## 9.714286 52978.85 51555.09 88.276107 1335.48747
```

```
xhat1.opt <- winter1.opt$fitted[,2]
```

Peramalan

#Forecast

```
forecast1 <- predict(winter1, n.ahead = 17)
forecast1.opt <- predict(winter1.opt, n.ahead = 17)
```

Plot Deret Waktu

#Plot time series


```
plot(training.ts,main="Winter 0.2;0.1;0.1",type="l",col="black",
      xlim=c(1,25),pch=12)
```

```

lines(xhat1,type="l",col="red")
lines(xhat1.opt,type="l",col="blue")
lines(forecast1,type="l",col="red")
lines(forecast1.opt,type="l",col="blue")
legend("topleft",c("Actual Data",expression(paste(winter1)),
                  expression(paste(winter1.opt))),cex=0.5,
      col=c("black","red","blue"),lty=1)

```

Winter 0.2;0.1;0.1



Akurasi Data Latih

```

#Akurasi data training
SSE1<-winter1$SSE
MSE1<-winter1$SSE/length(training.ts)
RMSE1<-sqrt(MSE1)
fitted_values <- winter1$fitted[,1]
abs_error <- abs(training.ts - fitted_values)
MAPE1 <- mean(abs_error / training.ts * 100)
akurasi1 <- matrix(c(SSE1,MSE1,RMSE1, MAPE1))
row.names(akurasi1)<- c("SSE", "MSE", "RMSE", "MAPE")
colnames(akurasi1) <- c("Akurasi")
akurasi1

##           Akurasi
## SSE  2.640113e+09
## MSE  2.146434e+07
## RMSE 4.632962e+03
## MAPE 7.586912e+00

```



```

SSE1.opt<-winter1.opt$SSE
MSE1.opt<-winter1.opt$SSE/length(training.ts)
RMSE1.opt<-sqrt(MSE1.opt)
fitted_values <- winter1.opt$fitted[,1]
abs_error <- abs(training.ts - fitted_values)
MAPE1.opt <- mean(abs_error / training.ts * 100)

akurasi1.opt <- matrix(c(SSE1.opt,MSE1.opt,RMSE1.opt, MAPE1.opt))
row.names(akurasi1.opt)<- c("SSE1.opt", "MSE1.opt", "RMSE1.opt", "MAPE1.opt")
colnames(akurasi1.opt) <- c("Akurasi")
akurasi1.opt

##              Akurasi
## SSE1.opt    1.362301e+09
## MSE1.opt    1.107561e+07
## RMSE1.opt   3.328005e+03
## MAPE1.opt   4.992731e+00

akurasi1.train = data.frame(Model_Winter = c("Winter 1","Winter1 optimal"),
                             Nilai_SSE=c(SSE1,SSE1.opt),
                             Nilai_MSE=c(MSE1,MSE1.opt),Nilai_RMSE=c(RMSE1,RMS
E1.opt), Nilai_MAPE=c(MAPE1,MAPE1.opt))
akurasi1.train

##      Model_Winter  Nilai_SSE Nilai_MSE Nilai_RMSE Nilai_MAPE
## 1      Winter 1  2640113408  21464337   4632.962   7.586912
## 2 Winter1 optimal 1362300629  11075615   3328.005   4.992731

```

Perhitungan akurasi menggunakan data latih menghasilkan nilai MAPE yang kurang dari 10% sehingga nilai akurasi ini dapat dikategorikan sebagai sangat baik. Selain itu, hasil akurasi skenario 2 (winter1 optimal) lebih baik dari skenario 1 (winter1) karena nilai SSE, MSE dan RMSE nya lebih kecil.

Akurasi Data Uji

#Akurasi Data Testing

```

forecast1<-data.frame(forecast1)
testing.ts1<-data.frame(testing_ma$harga)
selisih1<-forecast1-testing.ts1
SSEtesting1<-sum(selisih1^2)
MSEtesting1<-SSEtesting1/length(testing.ts1)
MAPEtesting1<-sum(abs(selisih1/testing.ts1$testing_ma.harga)*100)/length(test
ing.ts1$testing_ma.harga)

forecast1.opt<-data.frame(forecast1.opt)
selisih1.opt<-forecast1.opt-testing.ts1
SSEtesting1.opt<-sum(selisih1.opt^2)
MSEtesting1.opt<-SSEtesting1.opt/length(testing.ts1)
MAPEtesting1.opt<-sum(abs(selisih1.opt/testing.ts1$testing_ma.harga)*100)/len

```

```

gth(testing.ts1$testing_ma.harga)

akurasi1.test = data.frame(Model_Winter = c("Winter 1", "Winter1 optimal"),
                             Nilai_SSE=c(SSEtesting1, SSEtesting1.opt),
                             Nilai_MSE=c(MSEtesting1, MSEtesting1.opt), Nilai_M
APE=c(MAPEtesting1, MAPEtesting1.opt))
akurasi1.test

##      Model_Winter  Nilai_SSE  Nilai_MSE  Nilai_MAPE
## 1      Winter 1  6537934749  6537934749    24.90338
## 2 Winter1 optimal  7266406110  7266406110    26.19163

```

Perhitungan akurasi menggunakan data uji menghasilkan nilai MAPE lebih dari 10% sehingga nilai akurasi ini dapat dikategorikan sebagai cukup baik. Selain itu, hasil akurasi skenario 1 (winter1) lebih baik dari skenario 1 (winter1 optimal) karena nilai SSE dan MSEnya lebih kecil.

Winter Multiplikatif

Model multiplikatif digunakan cocok digunakan jika plot data asli menunjukkan fluktuasi musiman yang bervariasi.

Pemulusan

```

#Pemulusan dengan winter multiplikatif
winter2 <- HoltWinters(training.ts, alpha=0.2, beta=0.1, gamma=0.3, seasonal = "m
ultiplicative")
winter2$fitted

## Time Series:
## Start = c(2, 1)
## End = c(9, 11)
## Frequency = 14
##      xhat      level      trend      season
## 2.000000  70694.45  70344.57 -1146.632418  1.0216266
## 2.071429  64915.34  66697.13 -1396.713036  0.9941030
## 2.142857  59411.31  63416.24 -1585.130931  0.9608644
## 2.214286  55558.60  60536.17 -1714.624925  0.9445282
## 2.285714  54860.63  58084.96 -1788.282905  0.9744914
## 2.357143  52634.74  56042.06 -1813.744924  0.9706136
## 2.428571  52344.78  54431.33 -1793.443140  0.9944317
## 2.500000  50839.18  53179.95 -1739.236956  0.9883062
## 2.571429  50874.91  52339.39 -1649.369597  1.0036475
## 2.642857  48320.45  51952.43 -1523.128191  0.9581821
## 2.714286  53431.61  52464.31 -1319.627304  1.0447149
## 2.785714  56353.13  53187.04 -1115.391896  1.0822228
## 2.857143  54809.04  53510.70 -971.486695  1.0432026
## 2.928571  55725.29  55371.06 -688.301825  1.0190651
## 3.000000  52277.00  54307.06 -725.871333  0.9756596
## 3.071429  51001.86  53895.65 -694.426003  0.9586597
## 3.142857  51990.25  55952.59 -419.289056  0.9361996

```

##	3.214286	53754.14	57966.49	-175.970246	0.9301550
##	3.285714	57657.91	59496.87	-5.335007	0.9691784
##	3.357143	57724.79	59238.14	-30.674182	0.9749579
##	3.428571	58870.94	58578.77	-93.544349	1.0065951
##	3.500000	58009.27	57684.32	-173.634955	1.0086694
##	3.571429	57856.86	56307.26	-293.976994	1.0329131
##	3.642857	54010.40	54323.53	-462.952618	1.0027818
##	3.714286	57197.70	52897.17	-559.292685	1.0928547
##	3.785714	55913.04	50766.27	-716.453541	1.1171476
##	3.857143	53796.12	49370.76	-784.359309	1.1072257
##	3.928571	47643.11	47987.41	-844.258857	1.0106052
##	4.000000	46112.08	47720.40	-786.533297	0.9824905
##	4.071429	47447.48	47468.82	-733.038321	1.0152282
##	4.142857	45996.26	47437.60	-662.856721	0.9833568
##	4.214286	44858.92	47239.22	-616.408908	0.9621669
##	4.285714	44935.19	47165.56	-562.134017	0.9642036
##	4.357143	44695.54	46967.42	-525.734850	0.9624013
##	4.428571	46081.01	47022.41	-467.662103	0.9898241
##	4.500000	45534.46	46776.81	-445.456371	0.9828002
##	4.571429	45721.73	46417.95	-436.796635	0.9943581
##	4.642857	45245.44	46511.80	-383.731818	0.9808657
##	4.714286	48010.74	46020.93	-394.445597	1.0522559
##	4.785714	49506.02	45468.59	-410.235216	1.0987090
##	4.857143	48313.75	44740.52	-442.018274	1.0906408
##	4.928571	44540.22	43921.89	-479.679701	1.0252751
##	5.000000	43469.08	44070.29	-416.871490	0.9957772
##	5.071429	45181.24	44099.49	-372.264672	1.0332519
##	5.142857	43263.27	43843.12	-360.674807	0.9949594
##	5.214286	41734.72	43176.25	-391.294534	0.9754532
##	5.285714	40820.64	42378.02	-431.987871	0.9731705
##	5.357143	40494.35	41898.63	-436.727908	0.9766641
##	5.428571	40997.27	41606.41	-422.277788	0.9954627
##	5.500000	40194.57	41224.86	-418.204609	0.9850004
##	5.571429	41238.44	41282.88	-370.581769	1.0079715
##	5.642857	40133.43	41357.07	-326.105033	0.9781255
##	5.714286	43029.73	41357.42	-293.459631	1.0478710
##	5.785714	44561.78	41188.07	-281.048387	1.0893429
##	5.857143	43474.91	40589.07	-312.843258	1.0794186
##	5.928571	41832.56	40414.28	-299.037910	1.0428096
##	6.000000	40817.69	40736.15	-236.947243	1.0078639
##	6.071429	42414.58	41096.97	-177.171117	1.0365296
##	6.142857	40048.94	40787.71	-190.380197	0.9864921
##	6.214286	39386.90	40998.96	-150.216525	0.9642131
##	6.285714	40538.06	41770.35	-58.056334	0.9718494
##	6.357143	41760.20	42554.38	26.152932	0.9807345
##	6.428571	42608.93	42713.05	39.404191	0.9966430
##	6.500000	42663.17	42688.45	33.004037	0.9986357
##	6.571429	43711.45	42774.89	38.347915	1.0209796
##	6.642857	41989.68	42517.16	8.740136	0.9873905
##	6.714286	43923.66	41827.16	-61.134463	1.0516600

```
## 6.785714 44454.50 41303.20 -107.416707 1.0791031
## 6.857143 43878.30 40646.35 -162.360452 1.0838433
## 6.928571 42302.08 40043.28 -206.431362 1.0618832
## 7.000000 41199.66 40333.69 -156.747496 1.0254554
## 7.071429 41682.04 40494.91 -124.950059 1.0325014
## 7.142857 40431.37 40609.76 -100.970328 0.9980889
## 7.214286 40542.78 41013.48 -50.501317 0.9897419
## 7.285714 40963.07 41198.84 -26.914867 0.9949272
## 7.357143 40996.00 41627.63 18.654841 0.9843857
## 7.428571 43238.85 43280.60 182.086715 0.9948499
## 7.500000 45011.01 44699.28 305.746600 1.0001328
## 7.571429 47353.36 46332.65 438.508814 1.0124478
## 7.642857 47230.89 48228.35 584.227733 0.9675966
## 7.714286 53214.94 50534.19 756.388583 1.0375188
## 7.785714 54891.72 50981.20 725.450595 1.0615989
## 7.857143 58318.08 53611.00 915.885608 1.0695290
## 7.928571 60116.81 54841.40 947.337194 1.0775798
## 8.000000 57139.99 54393.61 807.824337 1.0351179
## 8.071429 57251.55 54337.76 721.457588 1.0398176
## 8.142857 54925.12 53649.06 580.441520 1.0128272
## 8.214286 52826.96 52593.46 416.837791 0.9965414
## 8.285714 52960.51 52204.12 336.219708 1.0079970
## 8.357143 52230.96 50615.63 143.748777 1.0289913
## 8.428571 50199.03 48881.63 -44.026610 1.0278768
## 8.500000 49273.72 47779.30 -149.857085 1.0345223
## 8.571429 49286.13 47172.47 -195.553884 1.0491564
## 8.642857 46510.72 46430.55 -250.190760 1.0071538
## 8.714286 46890.01 45812.84 -286.942256 1.0299634
## 8.785714 49961.65 45434.63 -296.068984 1.1068506
## 8.857143 46721.11 43813.79 -428.546588 1.0768895
## 8.928571 44162.34 42774.02 -489.669111 1.0444135
## 9.000000 42421.79 42270.49 -491.054393 1.0153748
## 9.071429 42404.77 42525.61 -416.437375 1.0070198
## 9.142857 41721.66 43107.21 -316.633414 0.9750197
## 9.214286 42802.44 43961.50 -199.541574 0.9780741
## 9.285714 43018.77 44812.50 -94.486855 0.9620009
## 9.357143 45257.67 46067.54 40.465805 0.9815577
## 9.428571 47318.37 47147.65 144.429701 1.0005560
## 9.500000 48809.79 47564.25 171.647181 1.0224964
## 9.571429 49737.52 47898.29 187.886156 1.0343413
## 9.642857 48336.47 48254.88 204.756475 0.9974584
## 9.714286 50374.18 48789.18 237.710865 1.0274806
```

```
xhat2 <- winter2$fitted[,2]
```

```
winter2.opt<- HoltWinters(training.ts, alpha= NULL, beta = NULL, gamma = NULL,
seasonal = "multiplicative")
winter2.opt$fitted
```

```

## Time Series:
## Start = c(2, 1)
## End = c(9, 11)
## Frequency = 14
##           xhat      level      trend      season
## 2.000000 70694.45 70344.57 -1146.6324176 1.0216266
## 2.071429 57839.08 59647.75 -1465.5779698 0.9941030
## 2.142857 52750.66 56423.48 -1524.3127618 0.9608644
## 2.214286 50754.92 55248.39 -1512.6498157 0.9445282
## 2.285714 51969.98 54807.23 -1476.8654659 0.9744914
## 2.357143 51626.85 54623.59 -1433.6760399 0.9706136
## 2.428571 53079.78 54758.30 -1381.2967784 0.9944317
## 2.500000 52925.30 54882.54 -1331.0167713 0.9883062
## 2.571429 54298.33 55371.24 -1270.2438513 1.0036475
## 2.642857 52815.49 56316.76 -1196.2446253 0.9581821
## 2.714286 60857.28 59308.89 -1056.3661883 1.0447149
## 2.785714 64550.28 60623.21 -977.1929493 1.0822228
## 2.857143 60891.32 59356.46 -986.8630192 1.0432026
## 2.928571 65175.83 64730.91 -774.4154443 1.0190651
## 3.000000 54907.83 55438.79 -1058.8796874 1.0097080
## 3.071429 52035.82 53550.24 -1086.5880605 0.9918453
## 3.142857 58686.76 61822.95 -774.0174918 0.9613070
## 3.214286 60657.24 64777.76 -649.4865852 0.9458737
## 3.285714 62807.48 64962.20 -621.6361133 0.9761724
## 3.357143 56960.16 59350.75 -788.2798772 0.9726393
## 3.428571 55707.47 56756.26 -848.6014285 0.9964194
## 3.500000 53864.79 55242.73 -870.8079772 0.9906728
## 3.571429 52306.70 52887.99 -920.3665476 1.0065247
## 3.642857 46765.11 49557.09 -1000.8706723 0.9631126
## 3.714286 51896.74 50471.28 -936.9137512 1.0476917
## 3.785714 49895.89 47138.33 -1016.9337849 1.0818382
## 3.857143 49094.89 47691.60 -964.4939505 1.0506725
## 3.928571 47161.48 47733.99 -930.8672478 1.0076566
## 4.000000 48950.09 49379.08 -844.8383828 1.0085681
## 4.071429 47657.41 48375.15 -850.1517837 1.0027861
## 4.142857 47604.35 50078.48 -764.8733390 0.9653390
## 4.214286 46486.93 49848.18 -747.0204844 0.9467584
## 4.285714 47707.93 49894.22 -720.5348670 0.9701924
## 4.357143 46214.57 48372.33 -747.2974808 0.9703839
## 4.428571 47701.69 48628.90 -713.7715257 0.9955455
## 4.500000 46256.60 47514.90 -727.1379738 0.9886475
## 4.571429 45959.35 46558.62 -734.7903327 1.0029574
## 4.642857 45370.41 47651.97 -673.7365560 0.9657753
## 4.714286 47778.32 46463.86 -690.9148718 1.0438113
## 4.785714 48397.85 45335.15 -705.5358443 1.0844335
## 4.857143 45732.24 44180.38 -720.5389227 1.0522874
## 4.928571 43630.64 43842.89 -707.7460092 1.0114869
## 5.000000 46029.70 46253.21 -603.6127619 1.0083264
## 5.071429 45071.68 45392.29 -612.2059556 1.0065118
## 5.142857 43206.90 45317.57 -594.2555468 0.9660933

```

##	5.214286	40692.02	43563.63	-632.9855040	0.9478549
##	5.285714	40227.22	42171.58	-658.3358669	0.9690213
##	5.357143	39991.75	41799.18	-648.7863334	0.9718435
##	5.428571	41272.75	42099.96	-617.0739875	0.9949344
##	5.500000	40330.36	41427.04	-618.9390877	0.9882930
##	5.571429	42195.53	42515.75	-561.9091148	1.0057610
##	5.642857	40915.76	42929.25	-529.3333620	0.9649963
##	5.714286	44368.89	43044.36	-507.8109394	1.0430769
##	5.785714	44978.74	42032.13	-524.6571544	1.0836300
##	5.857143	41505.21	39992.99	-575.2360741	1.0529573
##	5.928571	41550.12	41386.94	-509.4714489	1.0164553
##	6.000000	43442.11	43522.32	-421.1418098	1.0079100
##	6.071429	43301.08	43395.11	-411.3253236	1.0073817
##	6.142857	39862.31	41792.64	-451.1058625	0.9642194
##	6.214286	40387.02	43058.59	-393.7618165	0.9466118
##	6.285714	43765.15	45442.77	-300.9873229	0.9695043
##	6.357143	44335.23	45823.10	-278.2334141	0.9734407
##	6.428571	43479.97	44034.32	-328.6808835	0.9948367
##	6.500000	42058.83	42792.06	-359.1915948	0.9911853
##	6.571429	43084.98	43104.15	-336.7727568	1.0074262
##	6.642857	40320.24	42096.45	-359.1798456	0.9660490
##	6.714286	41606.97	40329.79	-406.1851524	1.0421647
##	6.785714	42608.37	39837.88	-409.0480347	1.0806400
##	6.857143	40365.53	38638.39	-435.4460540	1.0566078
##	6.928571	39416.53	39015.77	-408.3004519	1.0209561
##	7.000000	42826.28	42739.53	-270.3028886	1.0084074
##	7.071429	42425.06	42472.04	-270.2088080	1.0052896
##	7.142857	40924.53	42577.86	-257.6506663	0.9670210
##	7.214286	41566.15	43919.96	-204.2242600	0.9508282
##	7.285714	42346.19	43831.28	-200.3652670	0.9705547
##	7.357143	42869.29	44326.42	-177.1375992	0.9710076
##	7.428571	48659.21	49003.00	-15.0390596	0.9932891
##	7.500000	49172.55	49549.89	3.7275320	0.9923101
##	7.571429	51850.26	51460.48	67.4106371	1.0062562
##	7.642857	51893.38	53713.67	140.4087918	0.9635924
##	7.714286	59391.79	56760.33	237.4684672	1.0420013
##	7.785714	55398.30	51293.89	46.9761233	1.0790292
##	7.857143	61811.40	58137.23	273.9529832	1.0582117
##	7.928571	58947.95	57103.80	230.2904860	1.0281483
##	8.000000	53134.53	52618.47	72.8037513	1.0084123
##	8.071429	52711.57	52339.44	61.0537028	1.0059365
##	8.142857	48742.36	50280.96	-9.7318434	0.9695875
##	8.214286	46171.68	48615.15	-65.0396511	0.9510108
##	8.285714	49238.80	50668.98	5.7236282	0.9716643
##	8.357143	44816.48	45975.12	-151.2273544	0.9780155
##	8.428571	43601.38	44069.54	-209.8172370	0.9941099
##	8.500000	44346.46	44749.88	-180.0887693	0.9949893
##	8.571429	46852.17	46537.60	-114.3702322	1.0092398
##	8.642857	44462.46	46096.17	-125.2928852	0.9671874
##	8.714286	47550.71	46126.88	-120.0830816	1.0335585

```
## 8.785714 48995.21 45171.23 -147.9881198 1.0882204
## 8.857143 42531.08 40555.82 -297.1859317 1.0564464
## 8.928571 41503.97 40908.51 -275.4820270 1.0214344
## 9.000000 42691.19 42566.71 -210.9033604 1.0079184
## 9.071429 45028.21 45022.24 -121.8527848 1.0028468
## 9.142857 45137.20 46729.59 -60.7632485 0.9671809
## 9.214286 46244.65 48479.42 -0.2952989 0.9539086
## 9.285714 48107.15 49836.54 45.0380860 0.9644272
## 9.357143 49806.95 50992.55 82.1410365 0.9751786
## 9.428571 51374.86 51507.85 96.6070009 0.9955508
## 9.500000 49468.16 49537.01 27.5609942 0.9980548
## 9.571429 50161.56 49696.07 31.9526906 1.0087181
## 9.642857 48478.54 50067.57 43.2924043 0.9674258
## 9.714286 53031.76 51296.24 82.8803348 1.0321654
```

```
xhat2.opt <- winter2.opt$fitted[,2]
```

Peramalan

#Forecast

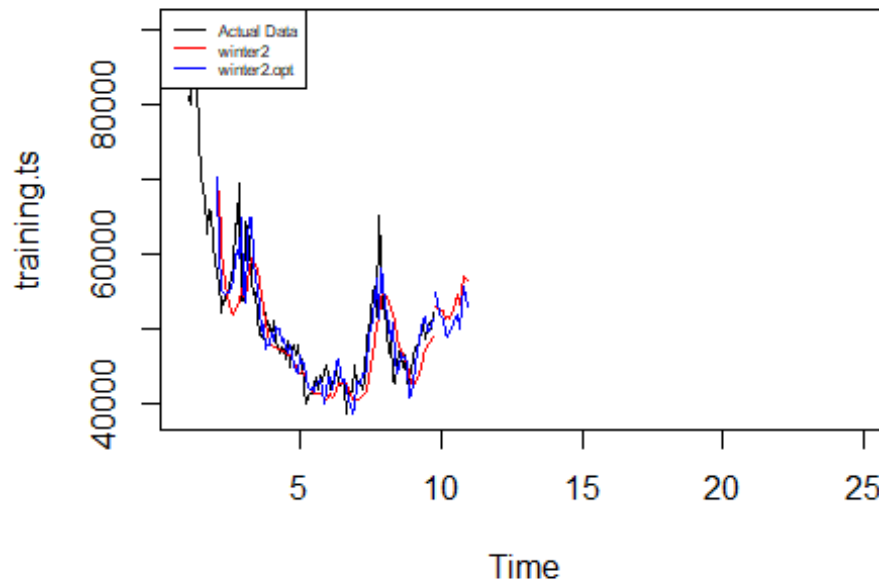
```
forecast2 <- predict(winter2, n.ahead = 17)
forecast2.opt <- predict(winter2.opt, n.ahead = 17)
```

Plot Deret Waktu

#Plot time series

```
plot(training.ts,main="Winter 0.2;0.1;0.1",type="l",col="black",
      xlim=c(1,25),pch=12)
lines(xhat2,type="l",col="red")
lines(xhat2.opt,type="l",col="blue")
lines(forecast2,type="l",col="red")
lines(forecast2.opt,type="l",col="blue")
legend("topleft",c("Actual Data",expression(paste(winter2)),
                  expression(paste(winter2.opt))),cex=0.5,
      col=c("black","red","blue"),lty=1)
```

Winter 0.2;0.1;0.1



Akurasi Data Latih

#Akurasi data training

```
SSE2<-winter2$SSE
```

```
MSE2<-winter2$SSE/length(training.ts)
```

```
RMSE2<-sqrt(MSE2)
```

```
fitted_values <- winter2$fitted[,1]
```

```
abs_error <- abs(training.ts - fitted_values)
```

```
MAPE2 <- mean(abs_error / training.ts * 100)
```

```
akurasi2 <- matrix(c(SSE2,MSE2,RMSE2, MAPE2))
```

```
row.names(akurasi2)<- c("SSE2", "MSE2", "RMSE2", "MAPE2")
```

```
colnames(akurasi2) <- c("Akurasi lamda=0.2")
```

```
akurasi2
```

```
##      Akurasi lamda=0.2
```

```
## SSE2      2.788558e+09
```

```
## MSE2      2.267120e+07
```

```
## RMSE2     4.761429e+03
```

```
## MAPE2     7.626018e+00
```

```
SSE2.opt<-winter2.opt$SSE
```

```
MSE2.opt<-winter2.opt$SSE/length(training.ts)
```

```
RMSE2.opt<-sqrt(MSE2.opt)
```

```
fitted_values <- winter2.opt$fitted[,1]
```

```
abs_error <- abs(training.ts - fitted_values)
```

```
MAPE2.opt <- mean(abs_error / training.ts * 100)
```



```

akurasi2.opt <- matrix(c(SSE2.opt,MSE2.opt,RMSE2.opt,MAPE2.opt))
row.names(akurasi2.opt)<- c("SSE2.opt", "MSE2.opt", "RMSE2.opt", "MAPE2.opt")
colnames(akurasi2.opt) <- c("Akurasi")
akurasi2.opt

##              Akurasi
## SSE2.opt  1.270486e+09
## MSE2.opt  1.032915e+07
## RMSE2.opt 3.213900e+03
## MAPE2.opt 4.619999e+00

akurasi2.train = data.frame(Model_Winter = c("Winter 2","winter2 optimal"),
                             Nilai_SSE=c(SSE2,SSE2.opt),
                             Nilai_MSE=c(MSE2,MSE2.opt),Nilai_RMSE=c(RMSE2,RMS
E2.opt))
akurasi2.train

##      Model_Winter  Nilai_SSE Nilai_MSE Nilai_RMSE
## 1      Winter 2 2788557948  22671203   4761.429
## 2 winter2 optimal 1270486004  10329155   3213.900

SSE2.opt<-winter2.opt$SSE
MSE2.opt<-winter2.opt$SSE/length(training.ts)
RMSE2.opt<-sqrt(MSE2.opt)
fitted_values <- winter2.opt$fitted[,1]
abs_error <- abs(training.ts - fitted_values)
MAPE2.opt <- mean(abs_error / training.ts * 100)

akurasi2.opt <- matrix(c(SSE2.opt,MSE2.opt,RMSE2.opt,MAPE2.opt))
row.names(akurasi2.opt)<- c("SSE2.opt", "MSE2.opt", "RMSE2.opt", "MAPE2.opt")
colnames(akurasi2.opt) <- c("Akurasi")
akurasi2.opt

##              Akurasi
## SSE2.opt  1.270486e+09
## MSE2.opt  1.032915e+07
## RMSE2.opt 3.213900e+03
## MAPE2.opt 4.619999e+00

akurasi2.train = data.frame(Model_Winter = c("Winter 2","winter2 optimal"),
                             Nilai_SSE=c(SSE2,SSE2.opt),
                             Nilai_MSE=c(MSE2,MSE2.opt),Nilai_RMSE=c(RMSE2,RMS
E2.opt),Nilai_MAPE=c(MAPE2,MAPE2.opt))
akurasi2.train

##      Model_Winter  Nilai_SSE Nilai_MSE Nilai_RMSE Nilai_MAPE
## 1      Winter 2 2788557948  22671203   4761.429   7.626018
## 2 winter2 optimal 1270486004  10329155   3213.900   4.619999

```

Perhitungan akurasi menggunakan data latih menghasilkan nilai MAPE yang kurang dari 10% sehingga nilai akurasi ini dapat dikategorikan sebagai sangat baik.Selain itu, hasil

akurasi skenario 2 (winter2 optimal) lebih baik dari skenario 1 (winter2) karena nilai SSE, MSE dan RMSE nya lebih kecil.

Akurasi Data Uji

#Akurasi Data Testing

```
forecast2<-data.frame(forecast2)
testing.ts<-data.frame(testing_ma$harga)
selisih2<-forecast2-testing.ts
SSEtesting2<-sum(selisih2^2)
MSEtesting2<-SSEtesting2/length(testing.ts)
RMSEtesting2 <- sqrt(MSEtesting2)
MAPEtesting2<-sum(abs(selisih2/testing.ts$testing_ma.harga)*100)/length(testing.ts$testing_ma.harga)
akurasi2 <- matrix(c(SSEtesting2, MSEtesting2, RMSEtesting2, MAPEtesting2))
row.names(akurasi2) <- c("SSE2", "MSE2", "RMSE2", "MAPE2" )
colnames(akurasi2) <- c("Akurasi lambda=0.2")
akurasi2

##          Akurasi lambda=0.2
## SSE2          6.255243e+09
## MSE2          6.255243e+09
## RMSE2         7.909010e+04
## MAPE2         2.419394e+01

forecast2.opt<-data.frame(forecast2.opt)
selisih2.opt<-forecast2.opt-testing.ts
SSEtesting2.opt<-sum(selisih2.opt^2)
MSEtesting2.opt<-SSEtesting2.opt/length(testing.ts)
RMSEtesting2.opt <- sqrt(MSEtesting2.opt)
MAPEtesting2.opt<-sum(abs(selisih2.opt/testing.ts$testing_ma.harga)*100)/length(testing.ts$testing_ma.harga)
akurasi2.opt <- matrix(c(SSEtesting2.opt, MSEtesting2.opt, RMSEtesting2.opt, MAPEtesting2.opt))
row.names(akurasi2.opt) <- c("SSE2", "MSE2", "RMSE2", "MAPE2")
colnames(akurasi2.opt) <- c("Akurasi Optimal")
akurasi2.opt

##          Akurasi Optimal
## SSE2          7.577437e+09
## MSE2          7.577437e+09
## RMSE2         8.704847e+04
## MAPE2         2.675819e+01

akurasi2.test = data.frame(Model_Winter = c("Winter2", "Winter2 optimal"),
                             Nilai_SSE=c(SSEtesting2, SSEtesting2.opt),
                             Nilai_MSE=c(MSEtesting2, MSEtesting2.opt), Nilai_RMSE=c(RMSEtesting2, RMSEtesting2.opt), Nilai_MAPE=c(MAPEtesting2, MAPEtesting2.opt))
akurasi2.test
```

##	Model_Winter	Nilai_SSE	Nilai_MSE	Nilai_RMSE	Nilai_MAPE
## 1	Winter2	6255243448	6255243448	79090.10	24.19394
## 2	Winter2 optimal	7577436717	7577436717	87048.47	26.75819

Perhitungan akurasi menggunakan data uji menghasilkan nilai MAPE lebih dari 10% sehingga nilai akurasi ini dapat dikategorikan sebagai cukup baik. Selain itu, hasil akurasi skenario 1 (winter2) lebih baik dari skenario 1 (winter2 optimal) karena nilai SSE dan MSEnya lebih kecil.

KESIMPULAN : Metode winter aditif lebih baik digunakan untuk skenario kedua (winter optimal) karena nilai SSE, MSE, RMSE, dan MAPEnya lebih kecil dibandingkan metode multiplikatif. Sedangkan sebaliknya metode multiplikatif lebih baik digunakan untuk skenario pertama (winter) karena nilai SSE, MSE, RMSE, dan MAPEnya lebih kecil dibandingkan metode aditif.

Kesimpulan Keseluruhan Metode

Berdasarkan keenam metode yaitu SMA, DMA, SES, DES, Winter Aditif dan Winter Multiplikatif, metode yang paling baik untuk digunakan adalah metode DES Skenario pertama karena secara keseluruhan nilai MAPEnya lebih rendah dibandingkan kelima metode lainnya. Adapun MAPE untuk seluruh metode berada di atas 10% yang berarti nilai akurasi data uji ini dapat dikategorikan sebagai cukup baik.